

Universität Stuttgart
Institut für Literaturwissenschaft
Prüfungsnummer: 1081810000
Annotation von Umweltphänomenen
WiSe 2024/25
Betreuung: Prof. Dr. Mareike Schumacher

**Annotation von Umweltphänomenen in Reiseberichten des 18. bis 20.
Jahrhunderts.**

Wie wird die menschliche Wahrnehmung von Natur in der Reiseliteratur linguistisch in den
Korpora *Arktis* und *Südamerika* beschrieben?

vorgelegt am

28.03.2025

von

Friedrich, Antonia (3489000); Li, Mengjiao (3392731) und Schulze, Judith (3318249)

3. FS M.A. Digital Humanities

Inhaltsverzeichnis

1. Abstract	2
2. Einleitung	2
3. Theoretische Einordnung	4
3.1 Forschungstradition	4
3.2 Konzept und Definitionen	7
4. Operationalisierung	9
5. Forschungsdesign	11
5.1 Korpus	11
5.2 Methoden und Tools.....	13
6. Dokumentation der Studie.....	17
6.1 Stanford NER	17
6.2 Word2Vec	19
6.3 Vis-À-Vis	25
6.4 Antconc	28
6.5 Gephi	30
7. Output.....	37
8. Anhang	39
8.1 Bibliographie	39
8.2 Internetwörterbücher und Enzyklopädien:	41
8.3 Methoden und Tools.....	41
8.3 Abbildungsverzeichnis	41

1. Abstract

Die Natur faszinierte den Menschen schon seit den ersten schriftlichen Aufzeichnungen. In Berichten hielten Reisende ihre Eindrücke und Erlebnisse fest, sodass diese Eindrücke damaliger Naturlandschaften aus der subjektiven Sicht der Autor:innen konserviert vorliegen. Anhand manueller und automatisierter Methoden werden Reiseberichte des 18. bis 20. Jahrhunderts zu den Kontinenten Arktis und Südamerika nach Landschaftsbeschreibungen und Naturphänomenen untersucht. Darüber hinaus soll untersucht werden, inwiefern sich die menschliche Wahrnehmung und Darstellung der Umwelt im Laufe der Zeit in Bezug auf die beiden ausgewählten Kontinente verändert hat. Dabei folgt die Untersuchung einem mehrstufigen Ansatz: Nach der manuellen Annotation von Test- und Trainingsdaten wird anhand dieser ein Modell für die automatisierte Annotation trainiert, um die Analyse auf eine größere Textdatenmenge auszuweiten. Anschließend liegt der Fokus auf der sprachlichen Charakterisierung der annotierten Entitäten. Mithilfe des Tools Word2Vec werden semantische Beziehungen zwischen diesen Begriffen analysiert sowie werden dazu ergänzend die jeweiligen Adjektiv-Kollokationen mit dem Tool AntConc untersucht. Diese Methoden ermöglichen es, sprachliche Muster in den Naturbeschreibungen der Reiseberichte detaillierter zu erfassen und nach ihrer Kategorieeinteilung vergleichend zu analysieren. Besonders sichtbar werden die Zusammenhänge zwischen den Texten, den untersuchten Kontinenten und den Naturdarstellungen mit den Visualisierungstools Vis-À-Vis und Gephi. Diese Analysen helfen, Unterschiede und Gemeinsamkeiten in der Wahrnehmung und Beschreibung der Umwelt in den Reiseberichten über verschiedene Zeiträume hinweg aufzuzeigen.

Der Bericht bietet dadurch eine Grundlage für weiterführende Forschungsarbeiten und die Entwicklung skalierbarer Lösungen in der Ökolinquistik sowie Umweltinformatik.

2. Einleitung

Der amerikanische Ökologe und Geophilosoph David Abram betont in seinem Werk *The Spell of the Sensuous* die wechselseitige Beziehung zwischen Mensch und Natur:

„The color of sky, the rush of waves – every aspect of the earthly sensuous could draw us into a relationship fed with curiosity and spiced with danger. Every sound was a voice, every scrape or blunder was a meeting – with Thunder, with Oak, with Dragonfly. [...] we are human only in contact, and conviviality, with what is not human“ (Abram 1996, S. 9)

Abrams Ansatz unterstreicht die Relevanz, Umweltphänomene nicht nur als physische Gegebenheiten zu verstehen, sondern sie vielmehr als aktive, sinnlich erfahrbare Akteure zu

begreifen. Gemäß dieser Überlegung wird die eigene Menschlichkeit erst durch die Begegnung mit dem Nichtmenschlichen spürbar. Für die Annotation von Umweltphänomenen in Texten bedeutet dies die Berücksichtigung, wie natürliche Elemente möglicherweise personifiziert oder als Akteure dargestellt werden. Die dies auslösenden, sprachlichen Mittel ermöglichen ein tieferes Verständnis dafür, wie Autor:innen die Beziehung zwischen Mensch und Umwelt in ihren Texten konstruieren.

Die Wahrnehmung der Natur in der Reiseliteratur ist daher eng mit kulturellen, historischen und sprachlichen Faktoren verknüpft. (Pastuszka, 2024) Die Gebiete der Arktis und Südamerikas bieten hierfür ein spannendes Untersuchungsfeld, da sie als Orte von extremer, geheimnisvoller oder unberührter Natur assoziiert werden könnten. Diese Darstellungen spiegeln nicht nur die geographischen und klimatischen Gegebenheiten wider, sondern auch die subjektiven Erfahrungen und Wahrnehmungen der Reisenden. Die linguistische Analyse der Reiseberichte ermöglicht es, die damaligen Beschreibungen von Natur/-landschaften oder -phänomenen sichtbar zu machen. Reiseberichte fungieren somit als Schnittstelle zwischen individueller Wahrnehmung und kollektiver Wissensproduktion über Natur.

Bei der Textgattung Reiseliteratur handelt es sich um eine überwiegend in Prosaform gestaltete literarische und meist dokumentarische Darstellung fiktiver oder realer Reisen. Sie zählt zu den ältesten Traditionsbeständen der Weltliteratur und stellt einen hybriden Gattungsbereich dar, der Elemente von Autobiografie, Tagebuch, Brief oder wissenschaftlicher Beschreibung miteinander verbinden kann. Charakteristisch ist daher die bereits erwähnte Verbindung von subjektiver Erfahrung, Fremdwahrnehmung und oft auch Wissensvermittlung. Besonders im 18. und 19. Jahrhundert gewann sie in Europa als Medium der Weltaneignung an Bedeutung. Reiseberichte dienten dabei nicht nur als Dokumentation für fremde Regionen, sondern auch als Mittel der kulturellen Selbstvergewisserung sowie der Aushandlung kolonialer Weltbilder. Sie sollten etwa als satirische Analysen der Gesellschaft dienen. Oder ausgehend von realen Weltreisen die europäische Perspektive auf ferne Regionen kritisch hinterfragen. (s. Brockhaus Enzyklopädie Online, Reiseliteratur, <https://brockhaus.de/ecs/enzy/article/reiseliteratur>, aufgerufen am 25.03.2025, NE GmbH Brockhaus) Im 20. Jahrhundert erlebte die Reiseliteratur einen weiteren Wandel: Sie wurde literarisch individualisierter, reflektierte koloniale Kontexte und griff zunehmend ökologische, politische und kulturelle Themen auf. Dies eröffnet ein breites Spektrum an Analyseperspektiven, insbesondere in Bezug auf Naturdarstellungen, Umweltwahrnehmung und das Verhältnis zwischen Mensch und Raum. (s. Brockhaus Enzyklopädie Online, Reiseliteratur, <https://brockhaus.de/ecs/enzy/article/reiseliteratur>, aufgerufen am 25.03.2025, NE GmbH Brockhaus) Die Reiseliteratur des 18. bis 20.

Jahrhunderts kann folglich ein umfangreiches Untersuchungsfeld für ökologische Analysen darstellen.

Die vorliegende Arbeit lässt sich mit Blick auf diese Grundlagen an einer Schnittstelle von Ökologie, Diskursanalyse und digitaler Literaturwissenschaft verorten. Untersucht werden Ansätze zur Annotation von Naturbeschreibungen in Reiseberichten des 18. bis 20. Jahrhunderts über die Kontinente Arktis und Südamerika unter Anwendung sowohl manueller als auch automatisierter Verfahren. Der Fokus liegt dabei auf der Analyse von Beschreibungen der Natur anhand der Kategorien *Landschaft* und *Naturphänomene* sowie ihren Adjektiv-Kollokationen, die die Umweltphänomene charakterisieren und eine vergleichende Untersuchung der Textkorpora ermöglichen.

3. Theoretische Einordnung

Im folgenden Kapitel soll die Seminarsstudie in den Forschungskontext eingebettet und der Forschungsstand zum Thema der Annotation von Umweltphänomenen sowie der Ökologie wiedergegeben werden. Anschließend sollen das Konzept der Studie und die Definitionen der Umweltbegrifflichkeiten, auf die sich die Studie stützt, genannt und erklärt werden, um ein Verständnis für die Herangehensweise an das ökologische Thema mit manuellen sowie automatisierten Methoden zu erzielen.

3.1 Forschungstradition

Bis heute ist das hauptsächliche Forschungsparadigma der Umweltdiskurse aus linguistischer Perspektive die Ökologie. Dieser interdisziplinäre Ansatz untersucht, wie Sprache unser Verständnis von Umwelt formt, beeinflusst und in gesellschaftlichen Kontexten behandelt wird. Der britische Historiker Robert Poole beschreibt die Ökologie als Analyse von Sprache im Hinblick auf ihre Rolle bei der Vermittlung und Konstruktion von Naturverhältnissen. In seiner Definition heißt es: „*how language mediates and shapes how people think about and engage with physical spaces, nonhuman animals, and the environment generally*“ (Poole 2022, 1). In seiner Studie verfolgt Poole einen korpusgestützten, ökologischen Ansatz. Auf Grundlage umfangreicher Textsammlungen analysiert Poole mittels Keyword-Analysen, Kollokationen und Konkordanzen die zentrale Forschungsfrage, wie Sprache das Denken des Menschen über nicht-menschliche Tiere und unberührte Natur sowie die menschliche Einordnung in der artenreichen Welt beeinflusst. Das Ziel seiner Analyse ist aufzuzeigen, inwiefern insbesondere massenmediale Diskurse anthropozentrische Perspektiven verstärken und damit potenziell ökologisch schädliches Verhalten legitimieren oder fördern.

In einer ähnlichen Studie setzt sich die australische Umweltschützerin Beth Schultz in *Language and the Natural Environment* (1992) mit der Rolle von Sprache in der Konstruktion von Umweltverhältnissen auseinander. Ihr Fokus liegt auf der Frage, wie sprachliche Praktiken die Wahrnehmung und Beschreibung der Natur prägen und beeinflussen, wie wir mit der Umwelt interagieren und welche Haltung gegenüber natürlichen Phänomenen dadurch gefördert wird. (Schultz 1992) Insbesondere analysiert sie, wie bestimmte sprachliche Ausdrucksweisen und metaphorische Strukturen unsere Vorstellungen von Natur strukturieren. Schultz geht der These nach, dass die Art, wie über Umwelt gesprochen wird, nicht nur Wahrnehmungsmuster beeinflusst, sondern auch das Verhalten gegenüber der Natur mitbestimmt und somit unter Umständen zur ökologischen Krise beitragen kann.

Eine weitere Untersuchung zur sprachlichen Auseinandersetzung mit Natur führt die Landschaftsökologin Dóra Drexler in ihrer Dissertation *Landschaft und Landschaftswahrnehmung* zum historischen Bedeutungswandel des Landschaftsbegriffs in verschiedenen Sprachen durch. (Drexler, 2009) Dabei erkennt sie, dass Begriffe wie das englische *landscape*, das französische *paysage*, das deutsche *Landschaft* und das ungarische *táj* keineswegs deckungsgleich übersetzt werden können, sondern unterschiedliche kulturelle und konzeptionelle Auffassungen von Natur und Umwelt zum Ausdruck bringen. Methodisch verbindet Drexler zwei sprachwissenschaftliche Zugänge zur Sprach- und Bedeutungsanalyse: Einerseits nutzt sie die klassische Wortfeldtheorie nach Trier (1931), wonach die Bedeutung eines Begriffs im Verhältnis zu benachbarten Begriffen innerhalb eines semantischen Feldes verstanden wird. Anhand dieser Theorie analysiert sie zentrale Ausdrücke in ihren relationalen Bedeutungszusammenhängen. Dieser Zugang wurde zudem durch einen sprachvergleichenden Ansatz nach Wandruszka (1969) ergänzt, indem Drexler lexikalische Entsprechungen direkt gegenüberstellt, um Unterschiede und Gemeinsamkeiten in der Bedeutungsstruktur verschiedener Sprachen zu erfassen. Dabei bezieht Drexler auch literarische Konnotationen und kulturelle Deutungsmuster mit ein, um die Vielfalt an Vorstellungen, die mit *Landschaft* sprachlich verknüpft sind, sichtbar zu machen. Sie weist jedoch darauf hin, dass die Untersuchung von gesprochener Sprache aufgrund methodischer Einschränkungen nur begrenzt möglich ist.

Neben den genannten Forschenden widmen sich auch die Geisteswissenschaftler Martin Döring und Francesca Zunino in *NatureCultures in Old and New Worlds. Steps towards an ecolinguistic perspective on framing a 'new' continent* (2014) der sprachlichen Repräsentation von Natur, allerdings im historischen Kontext kolonialer Diskurse. Sie analysieren die metaphorische Darstellung von Natur und Kultur (Flora, Fauna und indigene Bevölkerung) in

historischen und zeitgenössischen Texten über die Neue Welt (Amerika) aus der Perspektive der Alten Welt (Europa). Dabei gehen sie der Frage nach, wie Sprache dazu beiträgt, den amerikanischen Kontinent als *neuen, fremden und zu erschließenden* Raum zu konstruieren. Besonders deutlich wird eine sprachliche Rahmung des Kontinents an Sprachbildern wie *Wildheit, Zivilisation* oder *Besitz*, die nicht nur Wahrnehmungsmuster prägen, sondern zugleich ideologische Hintergründe und koloniale Machtverhältnisse transportieren. Methodisch greifen sie auf qualitative Diskursanalysen sowie metaphortheoretische Verfahren zurück, um lexikalische Felder, symbolische Strukturen und semantische Deutungsmuster in verschiedenen Textsorten herauszuarbeiten und miteinander zu vergleichen.

Abschließend sei die Studie des Linguisten Andrew Goatly anzuführen, der in seinem Artikel *Metaphor and Grammar in the Poetic Representation of Nature* (2017) untersucht, wie metaphorische Sprache und grammatische Strukturen die Darstellung von Natur in unterschiedlichen Textsorten prägen. Goatly widmet sich insbesondere der Frage, ob Natur in Texten als aktives Subjekt oder passives Objekt inszeniert wird und welche ökologischen Implikationen sich daraus ableiten lassen. Zur Analyse nutzt er die Transitivitätsgrammatik nach Michael Halliday sowie Metapherntheorie. Er kommt in seiner Studie zum Ergebnis, dass bestimmte Substantive und Nominalisierungen von Verben oder Adjektive die Natur sprachlich formen. In einem Vergleich poetischer Texte (zum Beispiel *The Prelude* von Wordsworth) mit umweltpolitischen Berichten wie dem *State of the World Report* (2012) arbeitet er heraus, dass Natur in literarischen Texten häufiger als handelnder Akteur erscheint, in Sachtexten hingegen überwiegend als Ressource. Goatly argumentiert, dass solche Darstellungen nicht nur sprachliche Stilmittel sind, sondern tiefgreifenden Einfluss auf das ökologische Bewusstsein nehmen. (Goatly 2017) Eine reflektierte Auseinandersetzung mit diesen sprachlichen Konstruktionen könnte daher zu einem nachhaltigeren und respektvollen Verhältnis zur Umwelt beitragen.

Vor dem Hintergrund dieser Forschungstradition lässt sich die vorliegende Arbeit in diese Forschungstraditionen einordnen, indem sie bestehende Ansätze der Ökolinquistik, Diskurs- und Metaphernanalyse auf das Feld historischer Reiseliteratur ausweitet. Aufbauend auf Arbeiten wie denen von Poole, Schultz, Dörning und Zunino oder Goatly soll untersucht werden, wie Natur sprachlich konstruiert und konzeptualisiert wird – allerdings mit einem Fokus auf Reiseberichte aus dem 18. bis 20. Jahrhundert, einem bislang weniger erforschten Textkorpus. Durch die Kombination qualitativer und quantitativer Analyseverfahren – insbesondere von Annotation, semantischer Netzwerke, Word-Embeddings und Kollokationsanalysen – wird ein methodischer Zugriff entwickelt, der sowohl die sprachliche Beschreibung als auch die

kulturelle Semantisierung von Umweltphänomenen sichtbar machen soll. Die Arbeit versucht damit diskurs- und bedeutungsanalytische Fragestellungen mit digitalen Verfahren der Textanalyse zu verbinden und erweitert den ökolinguistischen Forschungsrahmen um eine historische und digital gestützte Perspektive.

3.2 Konzept und Definitionen

Das theoretische Konzept dieser Arbeit basiert auf der Annotation von Eigennamen (Named Entities) in zwei Hauptkategorien von Umweltphänomenen: *Landschaft* und *Naturphänomene*. Der vorliegende Konzeptansatz begreift Umweltphänomene als natürlich auftretende, vom Menschen wahrnehmbare Phänomene, die in den analysierten Reiseberichten sprachlich beschrieben und konzeptualisiert werden. In den verschiedenen Quellen zeigt sich dabei ein breites Spektrum an Definitionen: Laut *Wikipedia* handelt es sich bei Naturerscheinungen als Synonym für Umweltphänomene um „dem Menschen erscheinende, sinnlich erlebbare natürliche Ereignisse, die sich auf natürliche Ursachen zurückführen lassen“. („Naturerscheinung“. In: Wikipedia – Die freie Enzyklopädie. URL: <https://de.wikipedia.org/w/index.php?title=Naturerscheinung&oldid=240033396>, abgerufen: 19. März 2025). Das *Digitale Wörterbuch der deutschen Sprache (DWDS)* betont in seiner Definition von *Naturereignis* insbesondere den Ausschluss menschlicher Macht: Es handelt sich um ein „nicht vom Menschen ausgelöstes Ereignis in der Natur“. („Naturereignis“, bereitgestellt durch das Digitale Wörterbuch der deutschen Sprache, <<https://www.dwds.de/wb/Naturereignis>>, abgerufen am 19.03.2025) Der *Brockhaus* wiederum fasst Naturereignisse enger als „außergewöhnliche und zeitlich begrenzte Vorgänge“, etwa meteorologischer, hydrologischer oder geologischer Art, die dann zu Naturkatastrophen werden können, wenn sie in die Lebenswelt des Menschen eingreifen. (Brockhaus Enzyklopädie Online, Landschaft (Geografie). <https://brockhaus.de/ecs/enzy/article/landschaft-geografie>, aufgerufen am 25.03.2025, NE GmbH Brockhaus) In den Reiseberichten werden unter anderem aufgrund ihres Charakters der Wissensvermittlung und Dokumentation sowohl geographische Landschaftsbeschreibungen (z. B. *Küsten*, *Wälder*, *Gebirge*) als auch Naturphänomene (z. B. *Regen*, *Wind*, *Erdbeben*) sprachlich thematisiert. Um diese unterschiedlichen Arten von Naturbeschreibungen zu trennen, wird zwischen den beiden Annotationskategorien *Landschaft* und *Naturphänomene*

unterschieden, die anhand der genannten Bedeutungsdefinitionen als Grundlage der Annotationsguidelines dienen.

Demnach wird die Kategorie *Landschaft* als topografisch fassbarer Teil der natürlichen Umwelt wahrgenommen. Der Begriff bezeichnet gemäß dem DWDS „einen Teil der Erdoberfläche, der durch Bodengestalt, Bewachsung, Besiedlung sein besonderes Gepräge erhalten hat und sich dadurch von anderen Gebieten unterscheidet“. („Landschaft“, bereitgestellt durch das Digitale Wörterbuch der deutschen Sprache, <https://www.dwds.de/wb/Landschaft>, abgerufen am 26.03.2025). Ebenso definiert der Brockhaus den Begriff *Landschaft* als räumlich konkrete Einheiten, die sich durch das Zusammenspiel geologischer, klimatischer und vegetationsbezogener Faktoren auszeichnen und so eine charakteristische Prägung erhalten. (Brockhaus Enzyklopädie Online, Landschaft (Geografie), <https://brockhaus.de/ecs/enzy/article/landschaft-geografie>, aufgerufen am 25.03.2025, NE GmbH Brockhaus) Vor diesem Hintergrund wurde die Annotationskategorie *Landschaft* im Projekt weiter differenziert und entlang bedeutungsbezogener Merkmale in fünf Tag-Kategorien untergliedert. Diese wurden auf Grundlage der Begriffsbedeutungen im DWDS sowie Brockhaus definiert; eine detaillierte Auflistung der Annotationsguidelines sowie der Entitäten, die den jeweiligen Tag-Kategorien zugeordnet werden können, kann im GitHub Projekt eingesehen werden. (s. GitHub: github.com/judymimses/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Annotationsguidelines.pdf)

Die Tag-Kategorien für *Landschaft* lauten:

- *Terra* für geologische Flächen wie *Acker*, *Wiese*, *Sand*, *Ufer*, usw.,
- *Gewässer* für Binnen- und Küstengewässer wie *Fluss*, *Meer*, *Bach*, *See*, usw.,
- *Gestein* für Formationen wie *Gebirge*, *Tal*, *Hügel*, usw.,
- *Wüsten_und_Steppen* für trockene und offene Landschaften wie *Wüste*, *Sandmeer*, *Steppe*, usw.,
- *Wald* für bewachsene Flächen wie *Wald*, *Bäume*, *Dschungel*, usw.,

Diese strukturierte Differenzierung erlaubt es, verschiedene landschaftliche Ausprägungen präzise zu annotieren und deren Beschreibung in den Reiseberichten sowohl qualitativ als auch quantitativ zu analysieren.

Im Vergleich zur Kategorie *Landschaft*, die sich durch ihre räumliche Stabilität und topografische Fassbarkeit auszeichnet, umfasst die Kategorie *Naturphänomene* nach den zuvor

angeführten Begriffsbedeutungen vor allem dynamische, zeitlich begrenzte und atmosphärisch wirksame Erscheinungen der Natur. Die Annotationskategorie *Naturphänomene* wurden nach diesen Begriffsdefinitionen in ebenfalls fünf Tag-Kategorien unterteilt. Diese Differenzierung zielt darauf ab, verschiedene Dimensionen natürlicher Prozesse präzise abzubilden:

- *Himmel* für Entitäten mit Bezug zur Erdatmosphäre wie Sonne, Mond, Sterne, usw.,
- *Wasser* für Entitäten mit Wasserbezug wie Flut, Regen, Schnee, usw.,
- *Geologie* für geologische Phänomene wie Erdbeben, Lawine, Vulkan, usw.,
- *Temperatur* für Entitäten mit Temperaturbezug wie Wärme, Kälte, Hitze, Kühle, usw.,
- *Sturm_Luft* für Wetterphänomene wie Wind, Böen, Sturm, usw.

Die Zielsetzung der kategorialen Unterscheidung und Annotation besteht darin, die sprachliche Darstellung und Konzeptualisierung von Umweltphänomenen in Reiseberichten systematisch zu erfassen. Auf diese Weise verbindet der vorliegende Ansatz linguistische sowie semantische und kulturwissenschaftliche Perspektiven zu einem integrativen Analysemodell für die sprachliche Umweltwahrnehmung in der Reiseliteratur.

4. Operationalisierung

Pichler & Reiter (2022) präsentieren ein Modell, das den Arbeitsablauf einer reflektierten literarischen Textanalyse skizziert (Abb. 1). Dieses Modell bildet die Grundlage für die Operationalisierung der Untersuchung zur sprachlichen Darstellung von Umweltphänomenen in der Reiseliteratur.




Abb. 1: Arbeitsablauf der reflektierten literarischen Textanalyse, Pichler & Reiter (2022)

Das Diagramm beginnt mit der Formulierung von Forschungsfragen, die eng mit den zugrunde liegenden Konzepten und Phänomenen verknüpft sind. In dieser Arbeit lautet die zentrale Forschungsfrage: Wie wird die menschliche Wahrnehmung von Natur in der Reiseliteratur des 18. bis 20. Jahrhunderts in den beiden Korpora *Arktis* und *Südamerika* linguistisch beschrieben? Um diese Frage empirisch zu untersuchen, müssen die theoretischen Konzepte in messbare Einheiten überführt werden – ein Schritt, der als Operationalisierung bezeichnet wird. Das Modell von Pichler & Reiter (2022) unterscheidet zwischen zwei parallelen Messverfahren: (1) Manuelle Messung – erfolgt durch ein Annotationsschema, das relevante Merkmale in den Texten systematisch erfasst und anschließend evaluiert wird – und (2) Automatische Messung – erfolgt durch regelbasierte oder maschinelle Lernverfahren, die ebenfalls einer Evaluation unterzogen werden. Als Datenbasis für beide Methoden dienen drei verschiedene Korpora – das Referenzkorpus (zur Entwicklung der Annotationskriterien), das Entwicklungskorpus (zur Verfeinerung und Evaluation) und das Anwendungskorpus (zur finalen Analyse). Die aus den Messungen gewonnenen Daten werden anschließend entweder durch manuelle Inspektion oder quantitative Analysen weiterverarbeitet, bevor sie in eine interpretative Reflexion der Ergebnisse münden.

Die in Kapitel 3.2 definierten Kategorien und das Konzept der Arbeit dienen als Grundlage für die Annotation der Reiseliteratur. Um die Forschungsfrage systematisch zu untersuchen, werden diese Kategorien im Rahmen eines Annotationsschemas operationalisiert und in den Texten markiert. Dies erfolgt sowohl durch manuelle Annotation als auch durch automatische Verfahren, die mithilfe von Named Entity Recognition (NER) umweltbezogene Begriffe identifizieren. Die manuelle Annotation wird als Goldstandard genutzt, um die automatische Kategorisierung zu überprüfen und zu optimieren. Zur Sicherstellung der Validität erfolgt eine Inter-Annotator-Agreement-Analyse, die eine hohe Übereinstimmung zwischen den menschlichen Annotatoren gewährleisten soll. Die automatische Annotation basiert auf regelbasierten Verfahren sowie Machine-Learning-Modellen, die Umweltphänomene auf Grundlage linguistischer Muster identifizieren. Nach der Annotation werden die Daten mittels quantitativer und qualitativer Methoden weiterverarbeitet, um sprachliche Muster und diachrone Entwicklungen zu analysieren. Die konkrete Umsetzung dieser Analyseverfahren wird in Kapitel 5.2 *Methoden und Tools* ausführlich beschrieben.

Da es sich um historische Texte handelt, ist es wichtig, neben der quantitativen Erfassung auch qualitative Analysen durchzuführen, um die sprachlichen Kontexte und Konnotationen von Umweltphänomenen besser zu verstehen. Die Annotationen werden anschließend in unterschiedlichen Analyseverfahren weiterverarbeitet, um die sprachliche Darstellung von

Umweltphänomenen zu untersuchen. Dabei kommen sowohl quantitative als auch qualitative Methoden zum Einsatz. Quantitative Methoden umfassen unter anderem Frequenzanalysen, um die Häufigkeit bestimmter Umweltphänomene zu bestimmen, sowie Kollokationsanalysen, um die sprachlichen Kontexte dieser Begriffe zu erfassen. Insbesondere die Verwendung von Adjektiven in Zusammenhang mit Umweltphänomenen kann Aufschluss darüber geben, wie Naturwahrnehmung in der Reiseliteratur sprachlich konstruiert wird. Ergänzend werden semantische Felder mithilfe von Word2Vec und Netzwerkvisualisierung in Gephi untersucht, um Bedeutungszusammenhänge und mögliche historische oder regionale Unterschiede in der Naturbeschreibung sichtbar zu machen. Die detaillierte Umsetzung dieser Analyseverfahren wird im Kapitel *Methodische Durchführung und Ergebnisse* (Kapitel 6.1) ausgeführt. In diesem Kapitel wird jedoch bereits der konzeptionelle Rahmen der Operationalisierung beschrieben, um die Grundlage für die spätere methodische Umsetzung zu schaffen.

Die Operationalisierung ist der Schlüssel zur Untersuchung der sprachlichen Konstruktion von Naturwahrnehmung, denn die vorgestellten Kategorien für Umweltphänomene und Landschaften ermöglichen eine strukturierte Erfassung und Analyse der Texte. Durch die Kombination von manueller Annotation und automatischer Erkennung können sowohl detaillierte qualitative als auch umfassende quantitative Aussagen über die sprachliche Darstellung von Natur in der Reiseliteratur getroffen werden. Der hier dargestellte Operationalisierungsprozess bildet die Grundlage für das methodische Vorgehen dieser Arbeit.

5. Forschungsdesign

Nach der Vorstellung der Konzeptidee und der Definitionen sowie der zuvor erläuterten Operationalisierung sollen im folgenden Kapitel die Zusammenstellung und Bearbeitung des Korpus sowie die in der Untersuchung verwendeten Methoden und Tools erläutert werden.

5.1 Korpus

Im Rahmen des Seminars *Annotation von Umweltphänomenen* wurde das Korpus Reiseliteratur zur Verfügung gestellt, das die Reiseberichte verschiedener Autor:innen über verschiedene Kontinente enthält. Folglich sei darauf hingewiesen, dass die Auswahl der darin enthaltenen Texte nicht durch die Verfasser:innen des vorliegenden Textes vorgenommen wurde. Die vorliegende Analyse stützt sich dabei auf Reiseberichte über Expeditionen und Reisen in die Arktis sowie nach Südamerika. Die Wahl dieser beiden Kontinentkorpora erfolgte mit der Intention, ein möglichst breites und vielfältiges Spektrum literarischer Darstellungen von sich unterscheidender Landschaft und Naturphänomenen zu erfassen. Die Arktis, eine polare Region rund um den Nordpol der Erde, ist durch extreme klimatische Bedingungen, vereiste

Landschaften und eine einzigartige, an Kälte angepasste Flora und Fauna charakterisiert. (s. „Arktis“, bereitgestellt durch das DWDS, <https://www.dwds.de/wb/Arktis>, abgerufen am 21.03.2025.) Im Gegensatz dazu befindet sich der Kontinent Südamerika auf der südlichen Seite des Doppelkontinent Amerikas und bietet eine Vielfalt von tropischen Regenwäldern bis hin zu kargen Landschaften. (s. Brockhaus Enzyklopädie Online, Südamerika, <https://brockhaus.de/ecs/enzy/article/sudamerika>, aufgerufen am 24.03.2025, NE GmbH Brockhaus) Die Berücksichtigung des Veröffentlichungsdatum und der Entstehungszeit erlaubt zudem potenzielle Veränderungen in der Wahrnehmung und sprachlichen Beschreibung von Natur zu erkennen. Die Textdaten der Kontinentkorpora sind digitalen Bibliotheken wie projekt-gutenberg.org (<https://www.projekt-gutenberg.org/>) und textgridrep.org (<https://textgridrep.org/>) entnommen und liegen in einem einheitlichen Format für die computergestützte Analyse vor. Die Dokumentation der verwendeten Werke, inklusive der Metadaten zu Autoren, Erscheinungsjahr und Textlänge, ist in Form einer Excel-Tabelle in einem archiviert. GitHub-Repository (github.com/judymimses/Seminarprojekt_Annotation_von_Umweltphaenomen/tree/main/Metadaten_Gutenberg_Korpus_Reiseliteratur) Die Tabelle enthält detaillierte Informationen zu den einzelnen Texten, unter anderem zu ihrer Wortzahl, Veröffentlichungsdatum und weiterer bibliografischer Daten, die zur Reproduzierbarkeit und Nachvollziehbarkeit der Zusammenstellung beitragen.

Der zeitliche Rahmen der Reiseberichte über die Arktis erstreckt sich von 1783 bis 1939 und umfasst damit sowohl frühe wissenschaftliche Erkundungen des späten 18. Jahrhunderts als auch Reiseberichte aus dem frühen 20. Jahrhundert. Zu den ältesten Texten zählt Georg Forsters *Bemerkungen über Gegenstände der physischen Erdbeschreibung, Naturgeschichte und sittlichen Philosophie auf seiner Reise um die Welt gesammelt* (1783), während das jüngste Werk *Eine Frau reist durch die Welt* von Maria Leitner 1932 veröffentlicht wurde. Die Textlängen variieren mit einer Anzahl von 44.514 bis 136.214 Token erheblich.

Das zweite Teilkorpus über Südamerika deckt einen Zeitraum von 1808 bis 1944 ab und bietet eine Darstellung von Landschaften und Naturphänomenen in der Reiseliteratur vom 19. bis zur Mitte des 20. Jahrhunderts. Zu den ältesten Texten zählt *Ansichten der Natur* von Alexander von Humboldt aus dem Jahr 1808, während das jüngste Werk *Amazonasfahrt* von Artur Heye 1944 veröffentlicht wurde. Wie im Korpus Arktis besteht auch im Korpus Südamerika eine große Variabilität der Textlänge von 37.635 bis 205.015 Token. Dies ermöglicht jedoch eine detaillierte Analyse sowohl komprimierter als auch umfangreicher Schilderungen.

Neben dem Analysekorpus, das als Grundlage für die Untersuchung der sprachlichen Darstellung von Umweltphänomenen dient, wurde ein zusätzliches Pilotkorpus erstellt. Dieses umfasst die Trainings- und Testdaten für die automatische Annotation, die mithilfe der Stanford Named Entity Recognition (NER) durchgeführt wird. Im nachfolgenden Kapitel wird die Entwicklung und Funktionsweise dieser Methode näher erläutert. Eine computergestützte Identifikation bedingt eine disjunkte Trainings- und Testdatenbasis, weshalb dieses Korpus aus verschiedenen Textquellen besteht. Es wurde darauf geachtet, nicht nur Texte mit direktem Bezug zu den untersuchten Regionen zu berücksichtigen, sondern auch solche, die andere geographische Räume thematisieren.

Das Trainingskorpus umfasst insgesamt 150.000 Token und besteht aus zwei Komponenten. Der größere Anteil von 120.000 Token entstammt dem GermanEcoCor Korpus (<https://ecocor.org/corpora/de>). Dieser Textkorpus umfasst nahezu die gesamten Texte aus dem GermanEcoCor, mit Ausnahme des Werkes *Pfisters Mühle*, welcher nicht in die Analyse aufgenommen wurde. Dieser Text fungierte zu Beginn als Datensatz für die Testdaten; Um jedoch Overfitting zu vermeiden, basieren die Testdaten im finalen Datensatz auf anderen Texten, wie später beschrieben wird. Der Durchschnitt der Tokenanzahl pro Text beläuft sich auf 5.000 Token. Ergänzend dazu wurden 30.000 Token aus Werken mit thematischem Bezug zur Reiseliteratur ausgewählt. Dabei ist anzumerken, dass Texte, die zum Korpus Südamerika oder die Antarktis gehören, im Sinne einer Vermeidung von Überanpassung/Overfitting ausgeschlossen wurden. Die herangezogenen Texte umfassen Passagen aus Kisch *Entdeckungen in Mexiko*, Frobenius *Der Kopf als Schicksal* und Goethe *Aus einer Reise in die Schweiz*. Das zur Untersuchung herangezogene Testkorpus umfasst 30.000 Token und beinhaltet willkürlich ausgewählte Reiseberichte aus den Korpora der Kontinenten Afrika und Asien. Die Integration dieser Texte in das Pilotkorpus ermöglicht eine gezielte Überprüfung der Generalisierbarkeit des Modells und trägt dazu bei, eine Überanpassung an die spezifischen Texte des Hauptkorpus zu vermeiden.

5.2 Methoden und Tools

Im Folgenden liegt der Fokus auf den ausgewählten Methoden, mithilfe derer Entitäten im Text annotiert und analysiert werden. Zunächst wurde eine manuelle Annotation durchgeführt, um eine qualitative Datenbasis für das Training und die Evaluierung eines maschinellen Klassifikators zu erstellen. Die manuelle Annotation ist ein Verfahren der manuellen Markierung und Klassifikation von Textelementen, welche insbesondere in der Sprachwissenschaft und digitalen Textanalyse zur Erstellung von Goldstandards Anwendung findet. Sie stellt eine Grundlage für maschinelle Lernverfahren dar, indem menschliche

Annotatoren festlegen, welche Textbestandteile als spezifische Entitäten klassifiziert werden (Jacke, 2018). Diese Annotationen erfolgen in der Regel in tabellarischer Form oder in für diesen Zweck entwickelten Annotationsprogrammen wie CATMA. Dabei werden Texte segmentiert und relevante Einheiten systematisch mit Annotationslabels versehen. Diese Klassifikation erfolgt dabei nach festgelegten Guidelines und definiert, welche Kategorien erfasst und wie diese annotiert werden sollen. In der Named Entity Recognition (NER) bezieht sich dies häufig auf Eigennamen wie Personennamen (PER), Ortsnamen (LOC) und Organisationsnamen (ORG) (Jacke, 2018; Schumacher, 2018a). Die manuelle Annotation spielt eine entscheidende Rolle bei der Erstellung von Trainings- und Testkorpora; Dadurch wird eine Kontrolle über die Kategorisierung von Entitäten ermöglicht. Infolgedessen können maschinelle Verfahren, aufbauend auf den manuellen Annotationen und den von Menschen geprüften Daten, trainiert und evaluiert werden, um Entitäten in den untersuchten Texten automatisch zu annotieren.

Für die digitalen Analysen des Gesamtkorpus, bestehend aus den Korpora über die Arktis und Südamerika, wird unter anderem der Stanford Named Entity Recognizer (NER) eingesetzt. Dieses Java-basierte Verfahren wurde im Rahmen der Stanford Natural Language Processing Group von Jenny Finkel, Dan Klein und Christopher Manning entwickelt und dient der automatischen Identifikation und Klassifikation von Eigennamen, insbesondere von Personen-, Orts- und Organisationsnamen. (Schubert, 2024) Basis der Anwendung ist ein probabilistisches Modell zur Sequenzklassifikation, das durch die Nutzung von Conditional Random Fields (CRF) kontextuelle Informationen zur verbesserten Entitätserkennung einbezieht. (Finkel et al., 2005) Standardmäßig umfasst der Stanford NER in seiner englischsprachigen Version die Entitätskategorien Person, Organisation und Location. Die Software unterstützt mehrere moderne Sprachen, darunter Deutsch, Englisch, Spanisch, Chinesisch und Italienisch. (Schumacher, 2019a) Eine detaillierte Anleitung zur Installation und Anwendung stellt die Plattform forTEXT bereit. Die Software kann über die Website der Stanford Natural Language Processing Group heruntergeladen werden. (Stanford NLP. (n.d.). Stanford Named Entity Recognizer (NER); <https://nlp.stanford.edu/software/CRF-NER.html>), abgerufen am 18. März 2025) Zusätzlich kann der Stanford NER mit eigenen Trainingsdaten erweitert werden, so dass er an spezifische Anwendungsfälle angepasst werden kann. Diese Möglichkeit ist insbesondere für die sprachwissenschaftliche Korpusanalyse von Interesse, da durch eine Anpassung des Modells auch domänenspezifische Entitäten erkannt werden können. Zur Erkennung von Entitäten analysiert das Modell verschiedene linguistische Merkmale, darunter Wortformen, Wortumgebungen und syntaktische Strukturen. Diese Merkmale werden

genutzt, um die Wahrscheinlichkeit zu bestimmen, mit der eine Zeichenfolge als Entität klassifiziert wird. Dadurch kann der Stanford NER nicht nur Einzelwörter, sondern auch mehrteilige Entitäten erkennen, die in einem bestimmten Kontext auftreten. (Finkel et al., 2005; Schubert, 2024)

Im Rahmen der vorliegenden Untersuchung wurde der Stanford NER zur Annotation und Analyse von Umweltphänomenen in literarischen Reiseberichten anhand der oben beschriebenen, zugrundeliegenden Trainings- und Testdaten eingesetzt. Es wurde auf disjunkte Trainings- und Testbasis im TXT-Format geachtet, um die Generalisierbarkeit des Modells sicherzustellen und eine Überanpassung/Overfitting zu vermeiden. (Schubert, 2024)

Nach der Klassifizierung von Entitäten können die gewonnenen Informationen mithilfe weiterer Tools weiterverarbeitet und analysiert werden: CATMA (Computer Assisted Text Markup and Analysis) ist ein webbasiertes Tool, das für die manuelle und halbautomatische Annotation, Analyse und Visualisierung von Texten konzipiert wurde. Es erlaubt sowohl die Erstellung individueller Tagsets als auch die kollaborative Annotation. (Schumacher, 2019b)

Die Nutzung von Word2Vec ist vor allem in Kombination mit Named Entity Recognition (NER) nützlich, um die semantische Nähe zwischen Entitäten zu analysieren. (Al-Saqqa & Awajan, 2019) Die technische Spezifikation von Word2Vec wurde von Mikolov et al. 2013 entwickelt, wobei das Ziel darin bestand, eine effiziente Methode zur Berechnung von Wortrepräsentationen in einem Vektorraum bereitzustellen. Die Methode basiert auf künstlichen neuronalen Netzwerken und kann große Textkorpora analysieren, um semantische Relationen zwischen Wörtern und ihren Kontexten zu modellieren. (Mikolov et al., 2013) Daher wird Word2Vec häufig in der Textanalyse und im Natural Language Processing (NLP) verwendet. Das Verfahren von Word2Vec basiert auf der distributionellen Hypothese, die besagt, dass Worte mit ähnlicher Bedeutung in ähnlichen Kontexten auftreten. (Firth 1964; Bojanowski et al., 2017; Gius et al., 2021) Bei der Analyse eines umfangreichen Korpus entstehen hochdimensionale Vektorräume, daher hat sich in der Forschung die Anwendung von Dimensionsreduktionen wie der Principal Component Analysis (PCA) oder der t-Distributed Stochastic Neighbor Embedding (t-SNE) als bewährt erwiesen. (Schumacher, 2023a) Die Funktionsweise von Word2Vec lässt sich nach zwei algorithmischen Ansätzen realisieren: Zum einen mit dem Continuous Bag-of-Words (CBOW)- und zum anderen mit dem Skip-Gram-Modell. Für die Sprachanalysen der Reiseberichte wurde das Word2Vec-Modell mithilfe der Jupyter Notebooks der *Lerneinheit Preprocessing mit NLTK* (Schumacher, 2022) erstellt und trainiert.

Für die weitere Analyse der identifizierten Entitäten und ihren zugehörigen Beschreibungen wurde außerdem das Tool AntConc genutzt. (Anthony, 2023) Die Texte des Korpus lassen sich in AntConc über verschiedene Verfahren wie z.B. mit Keyword in Context (KWIC) oder Kollokationen analysieren. Anhand der Kollokationen der Entitäten und ihren zugehörigen Adjektiven lassen sich thematische Assoziationen zwischen Begriffen erkennen und Rückschlüsse auf die narrative Einbettung in den Reiseberichten zu.

Eine besonders nützliche Methode, um Relationen von Kollokation und ihre Bedeutung sichtbar zu machen, ist zudem die Netzwerkanalyse. Dabei sollen die annotierten Entitäten als Knoten und deren Beziehungen als Kanten modelliert werden, um strukturelle Muster sichtbar zu machen. Die Kanten können dabei gerichtet oder ungerichtet sein, abhängig von der Art der Beziehung. (Schumacher, 2018b) Die Realisierung von Netzwerkanalysen kann auf unterschiedliche Weise erfolgen. Schumacher (2018b) führt drei zentrale Ansätze an:

- (1) die manuelle Erfassung von Merkmalen und deren Visualisierung mit Tools wie Gephi
- (2) ein semi-automatisches Verfahren, bei dem beispielsweise Kollokationen analysiert und in ein Netzwerkanalyse-Tool wie Ezlinavis übertragen werden
- (3) die Nutzung statistischer Daten aus Stilometrie-Tools wie Stylo zur weiteren Auswertung.

Im Folgenden wurden Netzwerkvisualisierungen mit Gephi erstellt. Die Verwendung grafischer Benutzeroberflächen und Anleitungen gewährleistet zudem, dass dieses Tool ohne Programmierkenntnisse analysiert werden kann. Es wird jedoch ein grundlegendes Verständnis für mathematische und statistische Verfahren vorausgesetzt, um Netzwerke adäquat zu interpretieren. (Schumacher, 2018b)

Für die visuelle Aufbereitung wurde neben den Netzwerken mit Gephi ebenfalls das webbasierte Visualisierungstool Vis-À-Vis verwendet. Im Gegensatz zu Tools wie VOYANT, das primär auf Textanalysen ausgerichtet ist, bietet Vis-À-Vis erweiterte sowie flexiblere Darstellungsmöglichkeiten für explorative Analysen. Besonders hervorzuheben ist die Fähigkeit des Tools, unabhängig von einer spezifischen Fragestellung einsetzbar zu sein und so ein Distant Reading im Sinne Morettis zu ermöglichen. (Münz-Manor et al, 2023) Die annotierten Korpora können aus externen Annotationsplattformen wie CATMA importiert und mithilfe verschiedener Visualisierungstechniken aufbereitet werden. Dazu gehören unter anderem distribution charts (dt. Verteilungsdiagramme) oder sunburst charts (dt. Strahlendiagramme), die Clustering im Text sichtbar machen. Anhand der Visualisierungsmöglichkeiten können nicht nur statistische Analysen ergänzt, sondern auch

neue Muster in den Daten erkannt werden, die durch eine rein textbasierte Betrachtung möglicherweise verborgen bleiben. (Münz-Manor et al, 2023)

6. Dokumentation der Studie

Nach der Operationalisierung und den Erläuterungen des Forschungsdesigns soll im folgenden Kapitel die methodische Durchführung der Analysen mit den im Kapitel zuvor vorgestellten Methoden und Tools erläutert und Ergebnisse der einzelnen Schritte präsentiert werden. Anschließend sollen einmal die Arbeitsweise sowie auch das methodische Vorgehen reflektiert werden.

6.1 Stanford NER

In einem ersten Schritt des Projekts wurde die maschinelle Annotation des Analysekorpus realisiert. Hierfür wurde mithilfe des Stanford Named Entity Recognizers (NER) ein domänenspezifisches Modell trainiert und anschließend evaluiert. Zur Vorbereitung des Modells wurde zunächst ein Trainings- und Testkorpus mithilfe von Microsoft Excel bearbeitet. Die Texte für die Annotation wurden zuvor segmentiert, sodass jedes Token in einer eigenen Zeile dargestellt wurde. Diese Formatierung diente der besseren Übersichtlichkeit sowie der Vorbereitung des TSV-Formats, das für das Training mit dem Stanford NER erforderlich war. Hierzu wurde eine annotierte Korpusmenge von insgesamt 180.000 Token verwendet: 150.000 Token für das Training und 30.000 Token für die Evaluation. Die manuelle Annotation erfolgte dabei durch drei unabhängige Annotator:innen anhand der im Abschnitt über Konzept und Definition erwähnten Annotationsguidelines. (s. GitHub: github.com/judymimses/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Annotationsguidelines.pdf)

Nach Abschluss der manuellen Annotation wurde eine Auswertung der Ergebnisse vorgenommen und Diskrepanzen diskutiert sowie gelöst. In Fällen von Abweichungen wurde entweder ein Mehrheitsentscheid herangezogen oder eine Konsensentscheidung getroffen. Das resultierende Ergebnis des Abgleichs wurde als Goldstandard bezeichnet und diente als Trainingsgrundlage für das maschinelle Lernverfahren. Die final abgestimmten Annotationen wurden in das von Stanford NER geforderte Format überführt und in zwei Dateien gespeichert: TSV_Goldstandard_Training_Final.tsv für das Training ([github.com/judymimses/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Dat ein_NER/TSV %20Goldstandard_Training_Final.tsv](https://github.com/judymimses/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Dat%20ein_NER/TSV_%20Goldstandard_Training_Final.tsv)) und TSV_vom_Goldstandard_Test_Final.tsv für die spätere Evaluation

([github.com/judymimmes/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Dat ein NER/TSV vom Goldstandard Test Final.tsv](https://github.com/judymimmes/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Dat%20ein%20NER/TSV%20vom%20Goldstandard%20Test%20Final.tsv)). Das Training des Modells wurde unter Verwendung des Stanford CRF Classifiers durchgeführt. Die hierfür verwendete Konfigurationsdatei `Final_Umwelt_Test.prop` ([github.com/judymimmes/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Dat ein NER/Final Umwelt Test.prop](https://github.com/judymimmes/Seminarprojekt_Annotation_von_Umweltphaenomen/blob/main/Dat%20ein%20NER/Final%20Umwelt%20Test.prop)) enthielt sämtliche notwendigen Parameter, einschließlich der Pfade zu den Datensätzen und Angaben zur Speicherauslastung.

Im darauffolgenden Schritt wurde das Modell auf den Testdatensatz angewendet und die Leistung anhand der Metriken Präzision (P), Recall (R) und F1-Score bewertet. Die Evaluierung ergab eine durchschnittliche Präzision von 0,8804, einen Recall von 0,5283 und einen F1-Score von 0,6603, was auf eine insgesamt solide Erkennungsleistung hinweist, jedoch ebenso eine begrenzte Generalisierbarkeit zeigt. Die Kategorien *Geologie* (F1 = 1.000), *Wüsten_und_Steppen* (F1 = 0.9024) und *Himmel* (F1 = 0.8400) wurden dabei besonders gut erkannt. Dies lässt den Schluss zu, dass die Begriffe dieser Klassen durch eindeutige lexikalische Muster und eine höhere Repräsentation im Trainingskorpus zuverlässig klassifiziert werden konnten. Die Kategorien *Gewässer* (F1 = 0.5122) und *Wald* (F1 = 0.5634) wiesen hingegen niedrigere Werte auf, was auf eine größere Variation in der sprachlichen Darstellung dieser Begriffe hindeutet. Auffällig ist die geringe Erkennungsrate der Kategorie *Temperatur*, die mit einem F1-Score von 0.000 keinerlei korrekte Vorhersagen lieferte. Dies könnte auf die geringe Anzahl an Trainingsbeispielen sowie die kontextabhängige Variabilität der Begriffe zurückzuführen sein. Auch *Sturm_Luft* (F1 = 0.6800) zeigte trotz hoher Präzision (P = 1.000) einen niedrigeren Recall (R = 0.5152) und bedeutet, dass viele tatsächlich vorkommende Begriffe dieser Kategorie nicht erkannt wurden. Die Resultate der Untersuchung weisen darauf hin, dass das Modell in erster Linie für Begriffe, die über eine klar definierte lexikalische Form verfügen und eine signifikante Repräsentation in den Trainingsdaten aufweisen, zuverlässige Ergebnisse liefert. Gleichzeitig weist das Modell Schwächen in Kategorien mit höherer grammatischer Variabilität oder geringer Datenbasis auf. Eine potenzielle Optimierung der Generalisierbarkeit des Modells kann demnach in einer Erweiterung der Trainingsdaten, insbesondere für die unterrepräsentierten Klassen, bestehen. Nach der Evaluierung wurde das Modell auf das Analysekorpus angewendet. Infolgedessen wurden die zugehörigen Textdateien automatisch mit Annotationen versehen, wobei jeder identifizierte Begriff mit der korrespondierenden Entitätsklasse verknüpft wurde. Die Ausgabeformate wurden zur Weiterverarbeitung in CATMA gespeichert.

Die Verwendung des Stanford Named Entity Recognizers stellte in der Arbeit die grundlegende Methodik dar, um Umweltphänomene im Analysekörper automatisiert zu identifizieren. Die Identifikation der Entitäten ist die Grundlage für die darauffolgenden systematischen Auswertungen und Analysen. Während der Erstellung eines fachspezifischen Modells wurde deutlich, dass dieser Arbeitsschritt eine sorgfältige Vorbereitung angefangen von der Segmentierung der Texte mittels eines Python-Skripts über die manuelle Annotation durch drei unabhängige Annotator:innen bis hin zur Konsolidierung eines Goldstandards erfordert. Der Goldstandard fungierte als essentielle Trainingsbasis für das Modell und dessen Leistung wurde anhand standardisierter Messwerte evaluiert. Die Evaluierung legt nahe, dass die Erkennungsleistung des Modells möglicherweise mit der Ausprägung lexikalischer Muster und der Häufigkeit bestimmter Klassen im Trainingskörper zusammenhängt. So könnten die vergleichsweise hohen Werte bei Kategorien wie *Geologie* oder *Wüsten_und_Steppen* darauf zurückzuführen sein, dass deren Begriffe über klare sprachliche Formen verfügen oder häufiger im Trainingsmaterial vertreten waren. Umgekehrt scheinen die schwächeren Ergebnisse bei Klassen wie *Temperatur* oder *Gewässer* auf eine geringere Datenbasis sowie eine höhere sprachliche Variabilität hinzudeuten. Diese Beobachtungen lassen vermuten, dass sowohl die Konsistenz als auch die Repräsentation der Trainingsdaten einen wesentlichen Einfluss auf die Modellleistung haben. Trotz solcher Einschränkungen erwies sich das Modell als geeignet, um strukturierte Informationen aus einem größeren Textkörper zu extrahieren und damit relevante Anhaltspunkte für die sprachliche Repräsentation von Umweltphänomenen zu liefern. Die Ergebnisse verdeutlichen jedoch auch, dass eine maschinelle Erfassung komplexer, kontextabhängiger Konzepte eine differenzierte Vorarbeit und kontinuierliche methodische Weiterentwicklung erfordert.

6.2 Word2Vec

Zur Vorbereitung des Körper für die Modellierung semantischer Relationen wurde zunächst eine Tokenisierung auf Satzebene durchgeführt. Zu diesem Zweck wurde das sogenannte Jupyter Notebook der Lerneinheit Preprocessing mit NLTK (Schumacher, 2022) herangezogen. Im Anschluss daran wurde mithilfe des Gensim-Pakets ein Vektormodell trainiert. Die methodische Umsetzung orientierte sich dabei an der *forTEXT-Lerneinheit Word2Vec* mit Gensim. (Schumacher, 2023b) Zu diesem Zweck wurde das zuvor vorbereitete Körper zunächst in eine zusammenhängende Datei überführt. Darauf aufbauend erfolgte eine Tokenisierung auf Wortebene, um sicherzustellen, dass das Modell die Wörter einzeln und in ihrem jeweiligen Kontext erfassen kann.

Ziel dieses Vorgehens war die Analyse der in den Reiseberichten verwendeten sprachlichen Beschreibungen von Umweltphänomenen, indem semantische Felder sowie Nähe-Relationen zwischen Begriffen sichtbar gemacht werden sollten. Folglich wurden mithilfe des Modells Wörter identifiziert, die in ähnlichen Kontexten wie die häufigsten Entitäten aus den annotierten Reiseberichten auftreten. Die Wörter mit den höchsten Ähnlichkeitswerten zu den jeweils fünf häufigsten Entitäten jeder Tag-Kategorie konnten durch gezielte Abfragen ermittelt werden. Um die Funktionsweise und Konsistenz des trainierten Modells zu überprüfen, wurde darüber hinaus mehrfach die Fähigkeit evaluiert, semantisch unpassende Begriffe zu erkennen. Hierfür wurde die Funktion *doesn't_match()* genutzt, die das Modell mit vier vorgegebenen Begriffen konfrontiert und dabei denjenigen Begriff ermittelt, der nicht in die semantische Reihe passt.

```
model.wv.doesnt_match(["Fluß", "See", "Regen", "Meer"])  
  
'Regen'
```

Abb. 2: Prüfung Word2Vec-Modell Beispiel 1.

```
model.wv.doesnt_match(["Berge", "Täler", "Felsen", "Meer"])  
  
'Meer'
```

Abb. 3: Prüfung Word2Vec-Modell Beispiel 2.

Demnach wurde der Begriff *Regen* als unpassend in der gewählten Gruppe *Fluß*, *See*, *Regen* identifiziert (Abb. 2). Diese Identifikation ist nachvollziehbar, da *Regen*, im Gegensatz zu den anderen Begriffen, kein geographisches Objekt beschreibt, sondern ein Naturphänomen ist. In einer weiteren Abfrage (Abb. 3) identifizierte das Modell den Begriff *Meer* als unpassend zu den Begriffen *Berge*, *Täler*, *Felsen*. Das Modell erkennt dementsprechend richtigerweise *Meer* als unpassend, da dieser der Tag-Kategorie *Gewässer* und nicht der Tag-Kategorie *Gestein* zugeordnet wurde.

Die Ähnlichkeitsabfragen für alle zehn Tag-Kategorien wurden in separaten TXT-Dateien gespeichert. Exemplarisch wird im Folgenden die Tag-Kategorie *Wald* näher betrachtet, um die Ergebnisse der Vektorähnlichkeitsberechnung zu illustrieren. Wichtig zu erwähnen ist, dass keine Lemmatisierung durchgeführt wurde, also Entitäten wie *Bäume*, *Bäumen*, *Walde*, *Wälder* und *Wald* als unterschiedliche Tokens behandelt wurden. Dies lässt den Schluss zu, dass insbesondere die Pluralformen in den Reiseberichten eine wichtige Rolle bei der Konzeptualisierung von *Wald* spielen. (Abb. 4-8)

Walde , Gänsemarsch , 0.8929163813591003 Busch , 0.8844102025032043 Hintergrunde , 0.8843766450881958 Grase , 0.8804147839546204 Dunkeln , 0.8764389157295227 Raume , 0.8736098408699036 Sacke , 0.8734204769134521 Zickzack , 0.8730781674385071 Sande , 0.8722395300865173 Waldesdickicht , 0.8571082353591919	Wald , Fjord , 0.8327300548553467 Sand , 0.8069852590560913 Strom , 0.8023037314414978 Urwald , 0.7780945897102356 Berg , 0.7756394743919373 Rauch , 0.7743805646896362 Bach , 0.772580087184906 Schlamm , 0.7705188989639282 Dunst , 0.7689056992530823 Busch , 0.7681015729904175	Wälder , Massen , 0.8607984185218811 Täler , 0.859962522983551 Seen , 0.8559305667877197 Gärten , 0.8540613055229187 Felder , 0.8495150804519653 Täler , 0.8485018610954285 Ebenen , 0.8448856472969055 Bäche , 0.8382923007011414 Dächer , 0.838164746761322 Schluchten , 0.8363756537437439
Bäume , Palmen , 0.869735836982727 Häuser , 0.8665931820869446 Felder , 0.8465049266815186 Vögel , 0.822942852973938 Blätter , 0.822344958782196 Wälder , 0.8204314112663269 Mauern , 0.8164522647857666 Spalten , 0.8163154721260071 Dörfer , 0.8091080188751221 Wände , 0.8063327670097351	Bäumen , Dächern , 0.8920024633407593 Palmen , 0.8907752633094788 Häusern , 0.8836999535560608 Mauern , 0.865536093711853 Hügeln , 0.8529888987541199 Feldern , 0.8525736331939697 Steinen , 0.8490444421768188 Büschen , 0.8405211567878723 Blättern , 0.8384667038917542 Blöcken , 0.8377067446708679	

Abb. 4-8: Beispiel der Ähnlichkeitswerte von 5 Entitäten der Kategorie *Wald*

Die Ähnlichkeitswerte zwischen den annotierten Entitäten und ihren jeweils zehn häufigsten Entitäten variieren in dieser Tag-Kategorie zwischen 0,76 und 0,89. Der niedrigste Wert wurde mit 0,76 zwischen *Wald* und *Busch* gemessen, was auf eine semantische Distanz hindeuten könnte – möglicherweise, weil ein einzelner *Busch* weniger stark mit der Vorstellung eines *Waldes* assoziiert wird als eine Vielzahl von *Büschen*. Den höchsten Ähnlichkeitswert von 0,893 erreichte die Kombination *Walde* und *Gänsemarsch*. Diese hohe Nähe könnte durch beispielsweise wiederkehrende Formulierungen wie *im Walde im Gänsemarsch* oder ähnliche sprachliche Vorkommen in den Trainingsdaten erklärt werden, die allerdings das Implementieren eines Close Distance Verfahren erfordern, um diese Auffassung fundiert belegen oder dementieren zu können.

Insgesamt können viele der Word-Embeddings – etwa *Grase*, *Dunkeln*, *Palmen*, *Vögel*, *Blätter*, *Waldesdickicht* oder *Urwald* – semantisch dem Wortfeld *Wald* und *Bäume* zugeordnet werden. Gleichzeitig treten auch Begriffe auf, die weniger eindeutig in diese Tag-Kategorie *Wald* passen, darunter *Fjord*, *Strom*, *Raume*, *Hintergrunde*, *Massen* oder *Häuser*. Diese Wörter erscheinen im semantischen Umfeld der fünf häufigsten Wald-Entitäten, weil sie in den Reiseberichten vermutlich gemeinsam mit Wäldern beschrieben werden. Denn in den insgesamt 50 ähnlichsten Entitäten lassen sich sowohl thematische Nähe als auch narrative Kookkurrenz widerspiegeln. Mittels t-SNE wurde dies in einer finalen Visualisierung der semantischen Felder deutlich. (Abb. 9) Um die Übersichtlichkeit zu gewährleisten, wurden hierfür die jeweils dreißig Word-Embeddings ausgewählt, die den häufigsten Wörtern in jeder Tag-Kategorie am ähnlichsten sind.




Abb. 9: t-SNE Visualisierung „Umweltphänomene_semantische Felder“ in Word2Vec.

Die häufigsten Entitäten *Insel* (lila), *See* (blau), *Bäume* (türkis), *Berge* (hellblau), *Wüste* (grün) repräsentieren dabei ihre Tag-Kategorien der Oberkategorie Landschaft, während *Erdbeben* (hellgrün), *Sonne* (gelb), *Wind* (hellorange), *Kälte* (orangerot) sowie *Wasser* (rot) die häufigsten Entitäten der Oberkategorie Naturphänomene darstellen.

Die t-SNE-Visualisierung offenbart eine deutliche Trennung entlang der Null-x-Achse zwischen den beiden Oberkategorien Landschaft (*Insel*, *See*, *Bäume*, *Berge*, *Wüste*) und Naturphänomene (*Erdbeben*, *Sonne*, *Wind*, *Kälte*, *Wasser*), was auf eine klare semantische Differenzierung hinweist. Die Begriffe innerhalb einer Kategorie sind signifikant näher zueinander gruppiert als zu Begriffen anderer Kategorien. Aus der relativen Positionierung der Begriffe lassen sich Rückschlüsse auf konzeptuelle Zusammenhänge ziehen. So befindet sich der Begriff *Dürre* beispielsweise in unmittelbarer Nähe zu *Wüste*, aber auch in semantischer Nähe zu *Erdbeben*. Dies legt nahe, dass Trockenheit oft mit geologischen Veränderungen assoziiert wird.

Die ähnlichsten Begriffe zur Entität *Insel* (lila) in der Kategorie *Terra* bilden ein zentriertes Cluster im Diagramm und stehen in unmittelbarer Nähe zu den Wortfeldern von *Wüste* und *See*. Die semantische Nähe zwischen *Insel* und *See* lässt sich geografisch erklären, denn Inseln sind definitionsgemäß von Wasser umgeben. („Insel“, bereitgestellt durch DWDS, <<https://www.dwds.de/wb/Insel>>, abgerufen am 23.03.2025) Die Verbindung von *See* und *Wüste* lässt sich hingegen durch die Inhalte der Reiseberichte interpretiert: Der Aufenthalt in

einer Wüste ist häufig mit der Suche nach Wasser verbunden, oder es werden Gewässer in Oasen beschrieben. Dies könnte erklären, warum beide Begriffe in den Texten häufig gemeinsam auftreten und dadurch im Vektormodell eine semantische Nähe aufweisen. Jedoch müsste hierfür Close Reading Verfahren angewendet werden, um diese These zu bestätigen.

Des Weiteren ist eine räumliche Nähe zwischen den Entitäten *Berge* (hellblau) für *Gestein* und *Bäume* (türkis) für *Wald* im t-SNE-Diagramm festzustellen. Diese semantische Verbindung lässt auf die häufige Darstellung bewaldeter Gebirgslandschaften in Reiseberichten schließen. Die Entitäten *Sonne* (gelb) und *Kälte* (orangerot), die den Kategorien *Himmel* beziehungsweise *Temperatur* zugeordnet sind, erscheinen etwas loser gruppiert, befinden sich aber beide im oberen linken Bereich des Diagramms. Dies verdeutlicht ihren konträren, aber ähnlichen Charakter als Naturphänomene. *Wind* (hellorange), der die Tag-Kategorie *Sturm_Luft* repräsentiert, liegt im Diagramm an einer Übergangsposition zwischen mehreren Clustern – insbesondere zwischen *Himmel*, *Temperatur*, *Geologie* und *Wasser*. Diese Zwischenstellung spiegelt die vielseitige Verwendungsweise des Begriffs wider, etwa in meteorologischen Kontexten wie Stürmen, in Verbindung mit Temperaturschwankungen oder als Teil atmosphärischer Beschreibungen.

Das Wortfeld um *Wasser* (rot) ist relativ geschlossen gruppiert, weist jedoch eine deutliche Abgrenzung zum Cluster um *Erdbeben* auf. Diese Trennung überrascht insofern, da Wasser in vielen Kontexten – etwa durch Regen, Sturm oder Temperaturveränderungen – mit anderen Naturphänomenen wie *Wind* oder *Kälte* in Verbindung gebracht werden kann. Auch topografisch tritt Wasser in Form von Seen, Flüssen oder Meeren regelmäßig in Kombination mit anderen Umweltmerkmalen auf. Die Positionierung des Clusters um den Begriff *Wasser* könnte darauf hindeuten, dass in den Reiseberichten eher isolierte Szenarien beschrieben werden, in denen Wasser nicht zwingend mit geologischen Veränderungen wie *Erdbeben* assoziiert wird. Besonders erscheint unter anderem die Position des Begriffs *Schnee*, der sich trotz seiner Zuordnung zur *Wasser*-Kategorie abseits der zugehörigen Word-Embeddings befindet. Diese abweichende Platzierung legt nahe, dass *Schnee* in den Reiseberichten stärker mit *Kälte* und *Temperatur* als mit anderen wasserbezogenen Begriffen verknüpft wird. Ein ähnliches Phänomen zeigt der Begriff *Himmel*, der ebenfalls eine eigenständige Position im semantischen Raum einnimmt. Die metaphorischen oder religiös-kulturellen Verwendung des Begriffs könnte diese semantische Absetzung des Begriffs von anderen Elementen seiner Tag-Kategorie begründen.

Für die Begriffe der Tag-Kategorie *Gestein* lassen sich ebenfalls markante semantische Gruppierungen beobachten: Die ähnlichsten Begriffe zur Entität *Erdbeben* sind im Diagramm

dicht beieinander positioniert und weisen kaum Ausreißer auf. Dies deutet darauf hin, dass geologische Veränderungen oder Aktivitäten in den Reiseberichten spezifisch und klar abgegrenzt beschrieben werden.

Interessant ist zudem die Struktur des Clusters *Wasser* (rot): Die Verteilung der ähnlichsten Begriffe scheint hier entlang der Präsenz oder Absenz menschlicher Aktivitäten organisiert zu sein. So gruppieren sich Begriffe wie *Fahrzeug*, *Boot*, *Verdeck* oder *Fahrwasser* eng zueinander und können zum Beispiel auf Beschreibungen der Seefahrt in den Texten hinweisen. Im Gegensatz dazu zeigt sich bei *Wind* und *Luft* eine breitere Streuung der semantisch verwandten Begriffe. Sie sind dabei stärker mit weiteren Entitäten aus den Kategorien *Himmel* und *Sturm_Luft* verknüpft, was auf die vielseitige Verwendung der Begriffe in verschiedenen Kontexten hindeutet.

Die Anwendung von Word-Embeddings mit Word2Vec ermöglicht, semantische Wortfelder zu erkennen und deren Struktur innerhalb des Korpus zu analysieren. In Bezug auf die Verteilung im Vektormodell wurde insbesondere bei den Begriffen der Oberkategorie *Landschaft* eine engere Gruppierung sichtbar. Hingegen wiesen die Entitäten der Kategorie *Naturphänomene* eine deutlich abweichende Gruppierung auf. Diese Trennung verdeutlicht, dass das Modell grundlegende semantische Differenzierungen nach Kategorien nachzuvollziehen kann. Zugleich kann beobachtet werden, dass einzelne Begrifflichkeiten - insbesondere solche aus den Bereichen *Gewässer* oder *Berge* - kategoriale Übergänge andeuten. Dies weist somit auch auf inhaltliche Nähe oder kontextuelle Überschneidungen in den Reiseberichten hin.

Es ist jedoch zu bedenken, dass die Aussagekraft dieser Analyse begrenzt ist, da pro Subkategorie lediglich der jeweils häufigste Begriff zur Modellabfrage verwendet wurde. Dadurch kann das gesamte Spektrum semantischer Felder nicht vollständig erfasst werden. Zudem ist die Modellqualität abhängig von der Größe und Homogenität des Korpus sowie den gewählten Trainingsparametern. Für eine weiterführende und differenzierte Analyse wären daher sowohl eine breitere Auswahl an Entitäten pro Kategorie als auch eine feinere Justierung des Modells erforderlich.

Hinsichtlich der semantischen Erfassung und Kategorisierung durch digitale Verfahren wie Word2Vec lassen sich Beschreibungen von Umweltphänomenen semantisch erfassen und nach semantischer Nähe visualisieren. Gleichzeitig wird deutlich, dass für tiefergehende literaturwissenschaftliche oder kulturwissenschaftliche Aussagen eine kontextsensitive Modellierung und die Kombination mit qualitativen Auswertungsverfahren notwendig ist.

6.3 Vis-À-Vis

Anhand der Annotationsdaten in den maschinell getaggten Textdateien konnten anschließend mithilfe des Tools Vis-À-Vis die Ergebnisse anschaulich interpretiert und verglichen werden. Das CATMA-Projekt wurde per Access Key in Vis-À-Vis synchronisiert und die Layouteinstellung als Kuchendiagramm gewählt werden, um die Verteilung der Tag-Kategorien in den einzelnen Texten sowie in den Korpora *Arktis* und *Südamerika* möglichst gut darzustellen. Für einen Gesamtüberblick wurde die gesamte Verteilung der annotierten Beschreibungen der Annotationskategorien *Landschaft* und *Naturphänomene* betrachtet: Im Kuchendiagramm (Abb. 10) zeigt sich eine erhöhte Dominanz der Landschaftsbegriffe, in Summe 71,7%. Dies könnte mit der Auswahl der Textdateien im Korpus begründet werden, in Reiseberichten sind die Beschreibungen der Landschaft üblich. Den höchsten Anteil der Kategorie *Landschaft* haben Begriffe, die als Tag der Kategorie *Terra* (29,6%) zugeordnet wurden, gefolgt von Begriffen der Kategorie *Gewässer* (23,4%). Die Dominanz lässt sich einerseits vermutlich anhand des historischen Hintergrunds der damaligen Reisen erklären, denn die Reisenden nutzten auf ihren Reisen nach Südamerika oder in die Arktis das Schiff und mussten zumeist von Europa kommend den Atlantik überqueren oder hinauffahren. Ebenso erfreuten sich die Schiffsreisenden vermutlich an dem sich nähernden Ufer und der unbekannten oder fremdländischen Landschaft, weshalb die große Anzahl an Begriffen der Tag-Kategorie *Terra* zu erklären ist.




Abb. 10: Kuchendiagramm des gesamten Korpus (*Arktis* und *Südamerika*) in Vis-À-Vis.

Der Anteil der Kategorie Gewässer verweist vermutlich auf viele Gewässer wie Flüsse oder Meere in Südamerika und in der Arktis. Allerdings könnte auch das trainierte Modell oder die Korpuszusammensetzung für diese Verzerrung verantwortlich sein.

Den größten Teil der Annotationskategorie *Naturphänomene* machen Nennungen von Begriffen der Tag-Kategorien *Himmel* (9,9%) und *Sturm_Luft* (9,7%) aus. Sie werden in Reiseberichten vermutlich bei Beschreibungen der Natur und der Umgebung der Reisenden häufiger verwendet. Obwohl die Temperatur eines der Merkmale der beiden Regionen – arktische Kälte und tropische Wärme/Hitze – sein mag, werden vergleichsweise selten Begriffe aus dieser Kategorie in den Berichten erwähnt. Möglicherweise beschreiben die Reisenden eher indirekt die Temperatur, daher wird im Diagramm der geringe Wert von 0,8% erreicht und visualisiert. Andernfalls wurden zu wenig Trainingsdaten für diese Tag-Kategorie im Modell verwendet, sodass es zu diesem Phänomen kommt.

Ein Vergleich der Tag-Kategorien von *Landschaft* und *Naturphänomene* in den Korpora *Arktis* (Abb. 11) und *Südamerika* (Abb.12) zeigt im Folgenden sowohl ähnliche als auch abweichende Verteilungen.




Abb. 11: Annotationsverteilung im Korpus *Arktis* in Vis-À-Vis.

Insgesamt dominieren wie im obigen Diagramm zum Gesamtkorpus die Tag-Kategorien *Terra* und *Gewässer*, allerdings ist der Anteil von *Terra* im Diagramm zur Arktis mit 30,0% höher als im Korpus zu Südamerika mit 27,7%. Dies kann auf die Landmassen und Bodenbeschaffenheiten in beiden Regionen hindeuten, aufgrund der besonders kargen

Landschaft wird in Reiseberichten über die Arktis diese Landschaft etwas hervorgehoben, jedoch ist der Unterschied gering und müsste in weiteren Untersuchungen mit gleich großen Korpora noch bestätigt werden.

Die Dominanz der Tag-Kategorie *Gewässer* sowohl im Korpus *Südamerika* mit 20,9 % als auch im Korpus *Arktis* mit 23,9 % lässt sich auf die zahlreichen Flüsse und das Meer in Südamerika sowie auf das natürliche höhere Vorkommen von Eis und Wasser in der Arktis zurückführen.




Abb. 12: Annotationsverteilung im Korpus *Südamerika* in Vis-À-Vis

Vergleichbare Anteile in den beiden Kontinent-Korpora hat die Tag-Kategorie *Gestein* mit 14,4% für *Südamerika* und mit 12,8% für *Arktis*. Dies kann Rückschlüsse auf die Topographie der Kontinente geben, sodass Gesteinsformationen wie Berge oder Abhänge in Reiseberichten beider Regionen ähnlich oft vorkommen. Die Beschreibung des Himmels als Naturphänomen fällt in beiden Korpora ähnlich aus, mit Anteilen von 10,6% für *Südamerika* und mit 9,7% für *Arktis*. In beiden Regionen scheinen demnach Wetter- und Himmelsphänomene ähnlich oft thematisiert zu werden, sind jedoch nicht das Hauptaugenmerk der Autor:innen.

Ein deutlicher Unterschied zeigt sich in der Oberkategorie *Naturphänomene* bei den Anteilen der Tag-Kategorie *Sturm_Luft*: Im Korpus *Südamerika* liegt der Anteil bei 5,7%, während er im Korpus *Arktis* mit 10,5% deutlich höher ist. Möglicherweise kann dies auf die extremen Wetterverhältnisse in der Arktis mit starken Winden und Schneestürmen verweisen. Noch deutlicher wird die unterschiedliche Beschreibung der Kontinente für die Tag-Kategorie *Wald*: Mit 11,3% werden Beschreibungen der Kategorie *Wald* in *Südamerika* weitaus häufiger in den

Reiseberichten verwendet als in *Arktis* mit lediglich 3,0%. Dies mag naheliegend sein und auf die unterschiedliche Topographie deuten, da es in Südamerika viele Bäume, Palmen sowie große Waldgebiete – wie unter anderem den Amazonas-Regenwald – gibt und in der Arktis aufgrund der klimatischen Verhältnisse nur sehr wenige bewaldete Gebiete zu finden sind.

Anhand der Anteile der Tag-Kategorie *Wasser* in *Naturphänomene* wird die größere Bedeutung von gefrorenem Wasser und Schnee in der Arktis sichtbar, denn mit 7,5% ist der Anteil der Kategorie höher als in den Reiseberichten über Südamerika mit nur 5,4%.

Aufgrund des geringen Anteils der Kategorie *Wüsten_und_Steppen* mit 2,1% für *Südamerika* und nur 1,0 % für *Arktis* kann auf das geringe Vorkommen von trockenen oder felsigen Landschaften in den beiden Kontinenten geschlossen werden. Naturbeschreibungen über geologische Naturphänomene werden am wenigsten in den Reiseberichten im Korpus *Südamerika* mit nur 1,1% und im Korpus *Arktis* 0,6% verwendet.

Zusammenfassend beziehen sich die Naturbeschreibungen in den Reiseberichten der beiden Kontinente vor allem auf die Kategorien *Terra* und *Gewässer*. In den Berichten über die Arktis werden dazu besonders Beschreibungen der Tag-Kategorie *Sturm_Luft* verwendet, während in Südamerika Beschreibungen bewaldeter Gebiete häufiger vertreten sind. Diese Unterschiede spiegeln die jeweiligen topographischen und klimatischen Gegebenheiten der beiden unterschiedlichen Regionen wider.

Diese visuelle Aufbereitung erwies sich auch im Hinblick auf die Fragestellung als nützlich, da sie half, geographisch und klimatisch bedingte Unterschiede in der Beschreibung von Umweltphänomenen zu identifizieren und vergleichend einzuordnen.

Andererseits musste jedoch mit technischen Einschränkungen in Vis-à-Vis gearbeitet werden. Das Laden der Website war teilweise instabil und erschwerte eine kontinuierliche Analyse. Auch der Import der CATMA-Projekte erforderte teilweise mehrere Versuche. Hinzu kam, dass die Farbzurordnung der Tags zwischen den Visualisierungen nicht konsistent blieb, obwohl die Diagramme im gleichen Bearbeitungszeitraum erstellt wurden. Diese Faktoren schränken die Vergleichbarkeit und Reproduzierbarkeit der Ergebnisse ein und sollten bei der zukünftigen Anwendung des Tools berücksichtigt werden.

6.4 AntConc

In Bezug auf die linguistische Darstellung der Entitäten in den beiden Hauptkategorien *Landschaft* und *Naturphänomene* wurde im Folgenden die Analyse der Kollokationen der annotierten Entitäten und den beschreibenden Adjektiven mit Hilfe von AntConc durchgeführt. (Anthony, 2023) Für diesen Analyseprozess wurde das Window Span in AntConc auf 1L to 0R eingestellt, da beschreibende Adjektive in der Regel direkt vor dem Nomen stehen. Außerdem

wurde aus Gründen der Effizienz in diesem Rahmen auf die Berücksichtigung eines größeren Kontextes als 1L verzichtet.

Nach der Extraktion der Adjektive erfolgt eine manuelle Bereinigung durch die Lemmatisierung und Rückführung auf die Grundform. So wurden etwa die Lexeme *groß*, *größer* und *großes* zu *groß* zusammengefasst und die Frequenzen addiert. Diese Auflistung erfolgte für die zehn häufigsten Adjektive, wobei die finale Liste der Kollokationen als Grundlage für die weitere Visualisierung diente. Die Auflistung ist in drei Spalten organisiert: Die erste Spalte enthält die extrahierten Adjektive, die zweite Spalte zeigt die jeweiligen Grundformen und die letzte Spalte präsentiert die jeweilige Häufigkeit. (s. GitHub: github.com/judymimses/Seminarprojekt_Annotation_von_Umweltphaenomen/tree/main/Kollokation) Darüber hinaus ist zu berücksichtigen, dass bei der Auswertung morphologische Varianten einzelner Begriffe – wie etwa *Meer* und *Meere* – zu einer einheitlichen Grundform zusammengeführt wurden. Auch diese Normalisierung floss in die anschließende Filterung der häufigsten Adjektive und ihrer Frequenzen mit ein. Ein Beispiel für das methodische Vorgehen lässt sich direkt aus der Kollokationsliste zu *Insel* entnehmen. (Abbildung 13) Die im Korpus gefundenen Formen *kleine* (38x), *grossen* (16x), *einsamen* (3x) oder *langgestreckten* (4x) wurden jeweils als modifizierende Adjektive identifiziert, lemmatisiert (zum Beispiel: *klein*, *groß*, *einsam*, *langgestreckt*) und in ihrer Frequenz gezählt. Damit wird sichtbar, welche Beschreibungen in den gewählten Reisetexten besonders häufig im Zusammenhang mit gewissen Adjektiven verwendet wurden.

Insel		
kleine	klein	38
grossen	groß	16
langgestreckten	langgestreckt	4
einsamen	einsam	3
flache	flach	3
südlichste	südlich	2
vulkanische	vulkanisch	2
unbewohnten	unbewohnt	2
weltberühmte	weltberühmt	2

Abb. 13: Ausschnitt der Liste bezüglich der Kollokation *Insel*.

Zusammengefasst ermöglicht die gewählte Methodik eine schnelle und systematische Erfassung adjektivischer Beschreibungen von geographischen Begriffen. Die Beschränkung auf einen Window Span von 1L bis 0R hat sich hier grundsätzlich als hilfreich erwiesen, da Adjektive im Deutschen typischerweise unmittelbar vor dem Substantiv stehen. Allerdings muss beachtet werden, dass durch diese Fokussierung der Analysekontext stark eingeschränkt wird. So ist es möglich, dass Adjektive, die weiter vom Substantiv entfernt stehen – zum

Beispiel durch Einschübe oder Attribute unterbrochen – nicht berücksichtigt wurden. Eine Wiederholung der Analyse mit erweiterten Window Span Einstellungen (zum Beispiel. 2L to 0R, 3L to 0R) könnte hier zusätzliche adjektivische Bezüge sichtbar machen, erfordert aber auch eine differenzierte Filterung, um irrelevante Treffer auszuschließen.

Ein weiteres methodisches Problem ergibt sich aus der semantischen Ambiguität der Begriffe. Nicht alle Begriffe, die als potenzielle Landschafts- oder Naturphänomene in Frage kommen, sind in jedem Kontext eindeutig zuzuordnen. Dies führt dazu, dass bei der automatisierten Extraktion auch Adjektive auftauchen können, die sich nicht auf die intendierte geographische Entität beziehen. Die nachträgliche manuelle Prüfung solcher Fälle ist notwendig, aber auch zeitaufwändig und nicht immer eindeutig lösbar.

Ungeachtet dieser Einschränkungen hat sich das beschriebene Verfahren als hilfreiches Instrument zur Beantwortung der Fragestellung erwiesen und erlaubt einen ersten quantitativen Zugang zur Untersuchung der linguistischen Beschreibung spezifischer Umweltphänomene sowie der Identifizierung von Adjektivmustern im historischen Diskurs über Reisen. Die Methode liefert somit nicht nur eine empirisch fundierte Datengrundlage, sondern macht auch Tendenzen in der sprachlichen Rahmung geographischer Entitäten sichtbar, die für die Interpretation literarischer Konstruktionen von Natur und Raum von zentraler Bedeutung sind.

6.5 Gephi

Aufbauend auf den in Word2Vec ermittelten Word-Embeddings der häufigsten Entitäten aus den Annotationskategorien *Landschaft* und *Naturphänomene* wurde ein semantisches Netzwerk in Gephi erstellt. Dadurch sollten die zuvor analysierten Bedeutungsähnlichkeiten zwischen den Begriffen visuell dargestellt werden. Hierzu wurden aus den beiden Annotationskategorien die jeweils fünf häufigsten annotierten Begriffe jeder Tag-Kategorie ausgewählt – für *Landschaft* die Kategorien *Terra*, *Gewässer*, *Wald*, *Gestein* und *Wüsten_und_Steppen*, für *Naturphänomene* die Kategorien *Sturm_Luft*, *Wasser*, *Geologie*, *Temperatur* und *Himmel*. Diese annotierten Entitäten bildeten die Knoten des Netzwerks und wurden jeweils mit den zehn ähnlichsten Begriffen aus Word2Vec verknüpft. Als Kanten des Netzwerks sollten die jeweiligen Messwerte der Bedeutungsähnlichkeiten aus den Analysen in Word2Vec dienen, die in Gephi als gerichtete Verbindungen visualisiert wurden. Für eine bessere Lesbarkeit wurde das *OpenOrd*-Layout gewählt und die Knotenabstände sowie Überlappungen angepasst.

Anhand des in Gephi erstellten Netzwerks (Abb. 14) zeigt sich eine auffällige semantische Verdichtung innerhalb der Kategorie *Naturphänomene*, insbesondere bei den Tag-Kategorien

Himmel, Wasser, Temperatur und *Sturm_Luft*. Begriffe wie *Sonne, Wellen, Himmel, Wind, Mond, Winde, Wolken, Nebel, Schnee, Sturm, Hitze, Kälte, Regen* werden im Netzwerk eng zusammen geclustert dargestellt und zeigen ein enges Netz an Verbindungen (farblich markiert in Lila, Pink, Blau und Orange).

Die Begriffe dieser Annotationskategorie weisen ähnliche Word-Embeddings auf, sodass die sprachliche Verbindung von klimatischen sowie meteorologischen Naturphänomene deutlich wird. Begriffe aus der Tag-Kategorie *Temperatur* wie *Kälte, Wärme* oder *Hitze* hängen eng mit solchen aus der Kategorie *Sturm_Luft* (z. B. *Wind, Sturm, Schnee*) zusammen. Diese werden wiederum mit *Himmel* und *Wasser* verwendet, was deren kontextuelle Verschränkung in den Quellentexten unterstreicht.

Auffällig ist die isolierte Position des Begriffs *Kühlung*, der keine direkte Verbindung innerhalb der sonst eng verknüpften Kategorie *Naturphänomene* aufweist. Möglicherweise hängt dies damit zusammen, dass *Kühlung* überwiegend in spezifischen Kontexten beschrieben wird – etwa in Reiseberichten über Südamerika, in denen Hitze eine Rolle spielt. Da im Netzwerk nur die zehn ähnlichsten Begriffe der häufigsten Entitäten berücksichtigt wurden, könnte ein solcher Zusammenhang hier nicht abgebildet worden sein.




Abb. 14: Netzwerk in Gephi der MFNE der jeweiligen Kategorien zu *Landschaft* und *Naturphänomene* und ihren mit Word2Vec analysierten ähnlichsten Wörtern.

Ebenfalls nennenswert ist die Positionierung der Begriffe aus der Tag-Kategorie *Geologie* (braun): *Erdbeben*, *Asche* und *Vulkan* stehen mit ihren Word-Embeddings weitgehend isoliert. Lediglich der Plural *Vulkane* weist semantische Verbindungen zu den Begriffen *Wüsten* und *Steppen* auf; Scheinbar könnte es Vulkane in der Nähe von Wüsten und Steppen geben, weshalb sie in den Reiseberichten über Südamerika und die Arktis eine ähnliche sprachliche Verwendung und Nennung finden.

Die Begriffe der Annotationskategorie *Landschaft* sind im Gegensatz zu den Begriffen der *Naturphänomene* weniger dicht geclustert. Selbst Begriffe derselben Tag-Kategorie weisen teilweise nur schwache Bedeutungsähnlichkeiten auf. Auffällig ist jedoch, dass besonders die Tag-Kategorien *Wald* (grün), *Gestein* (grau), *Gewässer* (hellblau) und *Wasser* (blau) ähnliche Word-Embeddings ausweisen. Beispielsweise sind Begriffe wie *Berg*, *Fluß*, *Wald*, *Felsen* und *Gipfel* über semantisch ähnliche Begriffe wie *Schluchten*, *Fjord*, *Strom* oder *Gletscher* miteinander verknüpft. Auch *Meer* und *Fluß* stehen über gemeinsame Wortähnlichkeiten mit *Gebirge* und *Berg* in Verbindung.

Anhand dieser Wortähnlichkeiten und dem gemeinsamen sprachlichen Auftreten kann auf die Topographie der Gebiete verwiesen werden: In bergigen Regionen mit Waldbewuchs werden häufig auch Gewässer wie Flüsse, Ströme oder Gletscher thematisiert. Der Begriff *Meer* hat außerdem Verbindungen zum Begriff *Wasser* aus der Kategorie *Naturphänomene* durch die ähnlichen Word-Embeddings *Eis*, *Packeis*, *Treibeis* sowie *Wasser* selbst. Diese Verbindungen verweisen auf die arktische Meereslandschaft mit gefrorenem Wasser.

Begriffe der Kategorie *Terra*, wie *Insel* oder *Küste*, erscheinen im Netzwerk vergleichsweise isoliert und haben nur wenige direkte semantische Verbindungen zu anderen Begriffen: Eine Ausnahme bilden die Begriffe *Insel* und *See*, die über den Begriff *Bucht* miteinander verbunden sind. Auch *Ufer* und *Lande* weisen jeweils nur vereinzelte kategorieübergreifende Verbindungen auf – etwa von *Ufer* zu *Felsen* sowie von *Lande* zu *Meere*, also zu Begriffen aus den Kategorien *Gestein* beziehungsweise *Gewässer*. Darüber hinaus lassen sich über ihre jeweiligen Word-Embeddings weitere, indirekte semantische Ähnlichkeiten zu Begriffen aus diesen beiden Kategorien erkennen. Insgesamt bleibt die semantische Vernetzung der Begriffe aus der Kategorie *Terra* jedoch schwächer ausgeprägt. Die textuellen Beschreibungen dieser Entitäten erlauben daher nur begrenzte Rückschlüsse auf ein konsistentes semantisches Feld. Dennoch lassen sich einzelne thematische Bezüge – etwa zwischen *Ufer* und hügeliger oder felsiger Landschaft sowie der Nähe zu Wasser – nachvollziehen.

Die Tag-Kategorie *Wüsten_und_Steppen* weist im Netzwerk eine vergleichsweise starke interne semantische Kohärenz auf. Begriffe wie *Sahara*, *Prärie*, *Pampa*, *Ebenen* und *Einöde*

sowie *Wüste*, *Steppe* und deren Pluralformen *Wüsten* und *Steppen* sind eng miteinander verknüpft. Lediglich der Begriff *Dünen* steht mit seinen Wortverbindungen allein. Möglicherweise ist dies auf eine zu geringe Zahl verfügbarer Word-Embeddings oder eine zu kleine Repräsentation des Begriffs im Korpus zurückzuführen. Verbindungen zu anderen Begriffen außerhalb der Kategorie bestehen nur vereinzelt. Neben einer semantischen Nähe zum Begriff *Vulkane* (aus der Tag-Kategorie *Geologie*) bestehen Verknüpfungen zur Kategorie *Wald*, etwa über die Begriffe *Wälder*, *Ebenen* oder *Täler*.

Mit Blick auf den bisherigen Erkenntnisstand zeigt die Netzwerkanalyse sowohl kategoriale Gruppierungen als auch semantische Ausreißer innerhalb einzelner Begriffe auf. Um diese Ergebnisse angemessen einordnen zu können, ist jedoch ein methodischer Aspekt zu berücksichtigen: Im Word2Vec-Modell wurde keine Lemmatisierung vorgenommen. Dies kann dazu führen, dass morphologisch verwandte Begriffe – etwa *Meeres* und *Meer* oder *Packeises* und *Packeis* – im Netzwerk nicht miteinander verbunden werden. Gleichwohl ermöglicht diese Entscheidung, die konkreten Wortformen und deren direkte semantische Beziehungen differenzierter zu erfassen. Auf diese Weise konnten die Verbindungen von Word-Embeddings der insgesamt 50 häufigsten Entitäten aus den Kategorien *Landschaft* und *Naturphänomene* dargestellt und miteinander verglichen werden.

Für die genauere Untersuchung und Interpretation der Beschreibungen und Wahrnehmung der Naturlandschaft und -phänomene wurde ein weiteres Netzwerk visualisiert, das die Kollokationen der häufigsten Entitäten des Gesamtkorpus mit den aus AntConc analysierten Adjektivfrequenzen enthält, die mindestens eine Frequenz von 2 haben. Zusätzlich wurde die Kantenbeschriftung für eine mögliche Interpretation der zeitlichen Veränderung der Naturbeschreibungen mit den Angaben des Erscheinungszeitraums nach Jahrhunderten *18. Jh. (grün)*, *19. Jh. (orange)* und *20. Jh. (pink)* visualisiert (Abb. 15).

Die Schriftgröße der Knoten entspricht dem Ausgangsgrad zu den Adjektivknoten, sodass unter anderem die Begriffe *Küste*, *Berg*, *Felsen*, *Wellen*, *Insel*, *Meer*, *Wasser*, *See*, *Wald*, *Baum* und *Wüste* die meisten Verbindungen zu Adjektiven haben. Die Kantendicke gibt die Frequenz der Adjektivvorkommen im Zusammenhang mit dem jeweiligen Begriff an. Dadurch zeigt sich beispielsweise eine besonders hohe Frequenz von *Berg* mit *hoch*, *Insel* mit *klein* und *groß* sowie *Meer* und *See* mit dem Adjektiv *offen*.

Wie im zuvor beschriebenen Netzwerk der Word-Embeddings ist auch im Netzwerk der Entitäten und Adjektiv-Kollokationen eine Trennung zwischen den Kategorien *Landschaft* (rot) und *Naturphänomene* (grün) deutlich anhand der Kantenfarbgebung zu erkennen. Scheinbar werden für die Wahrnehmung und Beschreibung dieser beiden Kategorien mehrheitlich

verschiedene Adjektive und Wortfelder verwendet. Die Begriffe der Kategorie *Landschaft* werden häufig mit Adjektiven beschrieben, die sich auf geographische oder physische Eigenschaften beziehen: Begriffe wie *Berg*, *Felsen* oder *Gipfel* (Tag-Kategorie *Gestein*) werden häufig mit Adjektiven wie *hoch*, *steil*, *kahl*, *zerklüftet* oder *schneebedeckt* näher charakterisiert.




Abb. 15: Netzwerkvisualisierung der Adjektiv-Kollokationen zu den häufigsten Entitäten des Gesamtkorpus.

Entitäten der Kategorie *Terra*, wie beispielsweise *Küste*, *Insel*, *Ufer*, *Lande* oder *Boden*, werden eher durch Adjektive wie *klein*, *groß*, *flach*, *fest*, *eben* oder durch Himmelsrichtungen wie *westlich*, *östlich*, *südlich*, *nördlich* beschrieben. Gewässer wie *Meer* und *See* werden ebenso anhand ihrer Beschaffenheit mit Adjektiven wie *offen*, *blau*, *tot* oder *grau* beschrieben. Ein charakteristisches Wortfeld an Adjektiven weist auch der Begriff *Wald* als häufigste Entität seiner Kategorie mit *dicht*, *tief*, *hoch*, *niedrig*, *groß*, *dunkel* auf. Interessanterweise überschneiden sich einige dieser Beschreibungen mit denen des Begriffs *Wolken*, was auf eine metaphorische oder visuelle Nähe in den Reiseberichten hindeuten könnte.

Im Vergleich zu den Begriffen der Kategorie *Landschaft* werden Entitäten der Kategorie *Naturphänomene* häufiger mit Adjektiven kombiniert, die auf Intensität, Bewegung oder Wirkung verweisen: Begriffe wie *Schnee*, *Luft*, *Nebel*, *Regen*, *Sturm*, *Wind* oder *Sonne* stehen

in Verbindung mit Adjektiven wie *stark, heftig, tief, strömend, furchtbar, glühend* oder *hell*. In den Reiseberichten werden demnach die Naturphänomene besonders anhand ihrer Dynamik und Wirkung beschrieben, während die Landschaft eher mit statischen Eigenschaften oder geografischen Attribute näher definiert wird.

Zwischen den beiden Annotationskategorie lassen sich thematische Übergänge erkennen, insbesondere zwischen *Gewässer* als Tag-Kategorie von *Landschaft* und *Wasser*, *Sturm_Luft* und *Himmel* als Tag-Kategorie von *Naturphänomene*. Die Entitäten *Meer* oder *See* sind beispielsweise über Adjektive wie *offen, still, blau, grau, stürmisch* oder *strömend* mit anderen Phänomenen wie *Wasser, Himmel, Flut, Luft, Nebel, Wolken* oder *Wellen* verknüpft. Diese Beschreibungen unterstreichen die Rolle des Wassers als dynamisches Element – sowohl in geographischer als auch in meteorologischer Hinsicht. Besonders deutlich wird dies in der Beschreibung von *Wasser, Schnee, Regen* und *Luft*, die durch Adjektive wie *tief, beständig, treibend, ewig* oder *fallend* charakterisiert werden. Diese Adjektive verweisen auf Aggregatzustände oder zyklische Naturprozesse und deuten diese Charakterisierung von Naturphänomenen in den Reiseberichten über Südamerika und die Arktis an.

Außerdem weisen Begriffe der Tag-Kategorien *Temperatur, Himmel* und *Sturm_Luft* häufig Kollokationen mit intensitätsbeschreibenden Adjektiven auf: Entitäten wie *Kälte, Hitze, Wärme, Sonne, Sturm, Regen* oder *Nebel* sind verbunden mit Wörtern wie *zunehmend, feucht, glühend, warm* oder *furchtbar*. Diese Beschreibungen deuten darauf hin, dass klimatische Bedingungen und Wetterphänomene in den Reiseberichten besonders als Begleiterscheinung auf der Reise thematisiert werden – etwa durch extreme Kälte und Schneestürme in der Arktis oder durch Hitze, tropische Niederschläge und Schwüle in Südamerika.

Innerhalb der Wortfelder der Landschaftsbegriffen treten häufig geografische oder herkunftsbezogene Adjektive auf, die entweder die Lage näher bestimmen oder auf spezifische Regionen und Landschaften verweisen. Diese geografischen Adjektive lassen Rückschlüsse auf die Auswahl und thematische Ausrichtung der Reiseliteratur zu: So treten beispielsweise in Verbindung mit dem Begriff *Küste* regionale Bezüge wie *grönländisch, brasilianisch* oder *sibirisch* auf. Dies kann als Hinweis auf konkrete geografische Fokussierungen in den Texten über die Arktis und Südamerika verstanden werden und durch Adjektive der Himmelsrichtung *nördlich, südlich, westlich* und *östlich* auf den wissenschaftlichen Charakter der Reiseberichte verweisen.

Insgesamt lassen die Adjektiv-Kollokationen zu den Entitäten in den Reiseberichten der beiden Kontinente Interpretationen über die Beschreibungen ihrer Landschaft und dort vorkommenden

Naturphänomene zu. Während Landschaftsformen vorwiegend über topographische Eigenschaften – etwa Größe, Höhe oder Materialbeschaffenheit – charakterisiert werden, beziehen sich Beschreibungen von Naturphänomenen stärker auf wahrgenommene Intensität und Wirkung. Besonders auffällig ist hierbei die sprachliche Präsenz extremer klimatischer Bedingungen sowohl für die Arktis als auch für Südamerika. Diese Beobachtungen stützen die Annahme, dass Reiseliteratur nicht nur geographische Gegebenheiten dokumentiert, sondern auch subjektive Wahrnehmungen und emotionale Eindrücke von Naturphänomenen der Reisenden reflektiert. Die Frage nach einer zeitlichen Veränderung in der Beschreibung von Naturphänomenen lässt sich auf Basis des Netzwerks jedoch nur eingeschränkt beantworten. Zwar wurden die Kanten entsprechend des Erscheinungszeitraums farblich markiert, doch zeigen sich keine systematischen Häufungen bestimmter Jahrhunderte bei einzelnen Begriffen oder Adjektiven. Vielmehr verteilen sich die zeitlichen Kantenbeschriftungen gleichmäßig über das Netzwerk. Eine diachrone Entwicklung lässt sich daher nicht nachweisen – möglicherweise aufgrund einer zu geringen Datenbasis oder weil sich sprachliche Muster in der Beschreibung von Naturphänomenen über die Jahrhunderte nur wenig verändert haben.

Zusammenfassend erwies sich die Netzwerkvisualisierung als sinnvolle Ergänzung zur Analyse der Wort-Embeddings: Durch die grafische Darstellung konnten Bedeutungsähnlichkeiten, Clusterbildungen und thematische Bezüge zwischen den häufigsten Entitäten und ihren adjektivischen Beschreibungen sichtbar gemacht und interpretiert werden. Besonders gut konnten Unterschiede und Überschneidungen zwischen den Kategorien *Landschaft* und *Naturphänomene* visuell nachvollzogen werden sowie semantische Felder und narrative Schwerpunkte in den Reiseberichten herausgearbeitet werden.

Gleichzeitig brachte die Methode einige Herausforderungen mit sich, denn die Netzwerkstruktur ist stark abhängig von den Einstellungen zur Kantenberechnung, der Layoutwahl sowie der Auswahl und Gewichtung von eingebundenen Daten. Zudem bleibt die Interpretation der Netzwerke stets visuell-intuitiv und bedarf einer reflektierten Deutung, da automatisierte Metriken allein für literarisch-narrative Kontexte nicht ausreichen.

Anhand der Netzwerkvisualisierungen in Gephi konnten semantische Strukturen der Beschreibungen in der Reiseliteratur der beiden Kontinente interpretiert werden. Die Visualisierungen stützen die Hypothese, dass Landschaft und Naturphänomene nicht nur unterschiedlich benannt, sondern entlang wahrnehmungsbezogener, räumlicher und atmosphärischer Dimensionen unterschiedlich konzeptualisiert und beschrieben werden.

7. Output

Die vorliegende Arbeit analysiert Umweltphänomene anhand der Kategorien *Landschaft* und *Naturphänomene* in Reiseberichten des 18. bis 20. Jahrhunderts mithilfe digitaler Methoden. Dabei werden Texte über die Arktis und Südamerika sowohl manuell als auch automatisiert annotiert, um sprachliche Muster in Naturbeschreibungen zu identifizieren und diachrone Entwicklungen sichtbar machen zu können.

Die Ergebnisse der Annotation können insgesamt eine Dominanz der Landschaftsbeschreibungen in den Reiseberichten zeigen, wobei besonders Begriffe aus den Tag-Kategorien *Terra* und *Gewässer* vermehrt vorkommen. Im Kuchendiagramm des Gesamtkorpus konnten 71,7% der annotierten Begriffe der Kategorie *Landschaft* zugeordnet werden, dabei haben *Terra* mit 29,6% und *Gewässer* mit 23,4 % den größten Anteil, gefolgt von *Gestein* mit 13,1%. Bei der Betrachtung der Verteilung von Annotationskategorien in den einzelnen Korpora konnte eine differenzierte Darstellung der Umweltphänomene festgestellt werden: Begriffe der Kategorie *Sturm_Luft* sind in den Reiseberichten über die Arktis mit 10,5% häufiger zu finden als in den Reiseberichten über Südamerika mit nur 5,7%. Zusätzlich kann anhand der Verteilung der Annotationskategorien auf die Topographie in den Kontinenten geschlossen werden, denn besonders Begriffe der Kategorie *Wald* belegen mit einem Anteil von 11,3% im Korpus zu Südamerika eine stärkere Bewaldung als im Korpus über die Arktis mit einem geringen Anteil von 3,0%. Die geringe Erwähnung von Begriffen der Kategorie *Temperatur* deutet darauf hin, dass klimatische Bedingungen oft eher indirekt beschrieben werden. Für die Untersuchung der Beschreibung und Wahrnehmung von Umweltphänomenen und der Natur können die Ergebnisse der semantischen Analysen der Word-Embeddings in Word2Vec interessante Erkenntnisse liefern: Mithilfe eines t-SNE kann eine getrennte Clusterung der häufigsten Begriffe der Kategorien *Naturphänomene* und *Landschaft* visualisiert werden. Die Begriffe aus der Kategorie *Landschaft* scheinen dabei besonders eng mit anderen bedeutungstragenden Wörtern genannt zu werden. Die Begriffe innerhalb einer Kategorie sind signifikant näher zueinander gruppiert als zu Begriffen anderer Kategorien. Aus der relativen Positionierung der Begriffe lassen sich Rückschlüsse auf konzeptuelle Zusammenhänge ziehen. Die semantische Nähe zwischen den Begriffen im t-SNE lässt sich meist geographisch sowie topographisch erklären, indem z. B. Inseln definitionsgemäß von Wasser umgeben sind oder die räumliche Nähe zwischen den Begriffen *Berge* (hellblau) als Entität für *Gestein* und *Bäume* (türkis) als Entität für *Wald* im t-SNE-Diagramm mit der semantischen Verwendung der Begriffe für die Darstellung bewaldeter Gebirgslandschaften in

Reiseberichten erklärt werden kann. Diese Gruppierungen spiegeln sowohl die natürliche Welt als auch die Wahrnehmungen der Autor:innen wider.

Die Analyse der Beschreibungen der Umweltphänomene anhand der Kollokationen zwischen annotierten Entitäten und ihren Adjektiven lässt ähnlich wie im Netzwerk der Word-Embeddings eine Trennung der Wortfelder *Landschaft* und *Naturphänomene* erkennen. Anhand der Netzwerkvisualisierung der Kollokationen in Gephi werden die Beschreibungen der Landschaft in den Reiseberichten meist durch topografische, geographische oder materielle Eigenschaften und Beschaffenheiten charakterisiert. Dabei haben z. B. die Tag-Kategorien *Gewässer*, *Gestein* und *Wald* ähnliche Wortfelder an Adjektiven. Hingegen vertiefen die adjektivischen Beschreibungen der Naturphänomene ihre natürlichen Kräfte und Intensität sowie wird dabei auch die subjektive Wahrnehmung der Reiseschriftsteller beschrieben. Vor allem Begriffe der Tag-Kategorien *Wasser*, *Sturm_Luft* sowie *Himmel* werden mit Adjektiven wie *heftig*, *stark*, *tief* oder *frisch* beschrieben und zusätzlich mit Adjektiven der Kategorie *Temperatur* verbunden, um die klimatischen Zusammenhänge der Wetterphänomene *Wind*, *Sturm* oder *Nebel* deutlicher zu beschreiben. Naturphänomene werden daher insgesamt besonders anhand der subjektiven Wahrnehmung mit Adjektiven näher beschrieben, während die Beschreibung der Landschaft anhand des Reisebericht-Charakters meist eher neutral und wissenschaftlich erfolgt.

Vor dem Hintergrund der Forschungstradition konnte die Studie ähnliche sprachliche Analysen zur menschlichen Wahrnehmung und Beschreibung von Natur liefern wie bereits Poole, Schultz, Dörning und Zunino oder Goatly in ihren Arbeiten sowie an die Forschungstradition der Ökolinquistik anschließen. Anhand der Word-Embeddings sowie der Adjektivkollokationen wurden sprachliche Muster in der Beschreibung von Landschaftsbegriffen und Naturphänomenen erkannt und auch gewisse gemeinsame oder ähnliche Wortfelder festgestellt sowie quantifiziert. Die gewonnenen Erkenntnisse sind im Kontext der gewählten methodischen Zugänge zu betrachten. Sie sind vielmehr in ihrer Form und Aussagekraft auch Ausdruck der Möglichkeiten und Grenzen der eingesetzten Verfahren. Die Kombination manueller und digitaler Methoden demonstrierte, dass jede Methode einen spezifischen Zugang zur sprachlichen Konstruktion von Umwelt ermöglicht und somit zur Beantwortung der Forschungsfrage beitragen kann. Die Methoden ermöglichen zwar kein vollständiges, aber ein vielschichtiges Bild der Naturwahrnehmung in der Reiseliteratur. Ihre Kombination – insbesondere von qualitativen und quantitativen Zugängen – erwies sich als zentrale Stärke der Studie.

8. Anhang

8.1 Bibliographie

Abram, David. (1996) *The Spell of the Sensuous: Perception and Language in a More-than-Human World*. New York: Pantheon Books, 1996.

Al-Saqqa, Samar, und Arafat Awajan. (2019). „The Use of Word2vec Model in Sentiment Analysis: A Survey“. S. 39–43 in *Proceedings of the 2019 International Conference on Artificial Intelligence, Robotics and Control*. Cairo Egypt: ACM.

Bojanowski, Piotr, Edouard Grave, Armand Joulin, und Tomas Mikolov. (2017). „Enriching Word Vectors with Subword Information“. *Transactions of the Association for Computational Linguistics* 5:135–46. doi: [10.1162/tacl_a_00051](https://doi.org/10.1162/tacl_a_00051).

Drexler, Dóra. (2009). *Landschaft und Landschaftswahrnehmung: Untersuchung des kulturhistorischen Bedeutungswandels von Landschaft anhand eines Vergleichs von England, Frankreich, Deutschland und Ungarn*.

Doering, Martin & Zunino, Francesca. (2014). NatureCultures in Old and New Worlds. Steps towards an ecolinguistic perspective on framing a ‘new’ continent. *Language Sciences*. 41. 10.1016/j.langsci.2013.08.005.

Eaton, Mark. (2016). The Environmental Imagination. *Christianity & Literature*. 65. 276-278. 10.1177/0148333116646046.

Finkel, Jenny Rose, Trond Grenager, und Christopher Manning. (2005) „Incorporating Non-Local Information into Information Extraction Systems by Gibbs Sampling“. S. 363–70 in *Proceedings of the 43rd Annual Meeting on Association for Computational Linguistics - ACL '05*. Ann Arbor, Michigan: Association for Computational Linguistics.

Firth, J. R. (1964). *Papers in Linguistics 1934-1951*. London: Oxford University Press.

Gius, E., Jacke, J., & Zehe, A. (2021). *Digital Humanities und die Literaturwissenschaft*. Berlin: De Gruyter.

Goatly, Andrew. (2017). "Metaphor and Grammar in the Poetic Representation of Nature." *International Journal of Language and Linguistics*, vol. 5, no. 2, 2017, pp. 10–22.

Jacke, Janina (2018): „Manuelle Annotation“. In: *forTEXT. Literatur digital erforschen*. URL: <https://fortext.net/routinen/methoden/manuelle-annotation> [Zugriff: 27. März 2025].

- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space*(Version 3). arXiv. <https://doi.org/10.48550/ARXIV.1301.3781>
- Pastuszka, Anna. (2024). "Europe's Cultural Landscapes in Travel Literature. An Introduction." *Lublin Studies in Modern Languages and Literature*, vol. 48, 1, 2024, pp. 1–18, <https://doi.org/10.17951/lsmll.2024.48.1.1-18>.
- Pichler, Axel, and Nils Reiter. (2022): "From Concepts to Texts and Back: Operationalization as a Core Activity of Digital Humanities." *Journal of Cultural Analytics*, vol. 7, no. 4, Dec. 2022, <https://doi.org/10.22148/001c.57195>.
- Poole, Robert. (2022) *Corpus-Assisted Ecolinguistics*. London, Bloomsbury Publishing, xvi+224 pp. ISBN: 978-1-3503-2042-0 (hbk)
- Re, Anna. (2024) *Discourse Analysis and the Environment: Ecolinguistic Perspectives*. LED Edizioni Universitarie.
- Schubert, C. (2024). Textanalyse digital. In C. Antenhofer, C. Kühberger & A. Strohmeyer (Hrsg.), *Digital Humanities in den Geschichtswissenschaften* (S. 144–165). Köln: Böhlau.
- Mareike Schumacher (2018a): „Named Entity Recognition (NER)“. In: forTEXT. Literatur digital erforschen. URL: <https://fortext.net/routinen/methoden/named-entity-recognition-ner> [Zugriff: 27. März 2025].
- Mareike Schumacher (2018b): „Netzwerkanalyse“. In: forTEXT. Literatur digital erforschen. URL: <https://fortext.net/routinen/methoden/netzwerkanalyse> [Zugriff: 27. März 2025].
- Mareike Schumacher (2019a): Named Entity Recognition mit dem Stanford Named Entity Recognizer“. In: forTEXT. Literatur digital erforschen. URL: <https://fortext.net/routinen/lerneinheiten/named-entity-recognition-mit-dem-stanford-named-entity-recognizer> [Zugriff: 27. März 2025].
- Mareike Schumacher (2019b): „CATMA“. In: forTEXT. Literatur digital erforschen. URL: <https://fortext.net/tools/tools/catma> [Zugriff: 27. März 2025].
- Mareike Schumacher (2023a): „word2vec“. In: forTEXT. Literatur digital erforschen. URL: <https://fortext.net/routinen/methoden/word2vec-1> [Zugriff: 27. März 2025].
- Schultz, Beth. (1992) "Language and the Natural Environment." *The Ecolinguistics Reader: Language, Ecology and Environment*, edited by Alwin Fill and Peter Mühlhäusler, Continuum, 2001, pp. 109–114.

8.2 Internetwörterbücher und Enzyklopädien:

Wikipedia – Die freie Enzyklopädie: <https://de.wikipedia.org/>

Digitale Wörterbuch der deutschen Sprache (DWDS): <https://www.dwds.de/wb/>

Brockhaus: <https://brockhaus.de/ecs/enzy/article/>

8.3 Methoden und Tools

Anthony, L. (2023). AntConc (Version 4.2.4) [Computer Software]. Tokyo, Japan: Waseda University. <https://www.laurenceanthony.net/software/AntConc> (Letzter Zugriff: 23.03.2025).

Bastian, M., Heymann, S., and Jacomy, M. (2009). Gephi: An open-source software for exploring and manipulating networks. *Proceedings of the International AAAI Conference on Web and Social Media*, 3(1), 361–362. <https://doi.org/10.1609/icwsm.v3i1.13937>

Gius, E., J. C. Meister, M. Petris, M. Meister, C. Bruck, J. Jacke, M. Schumacher, M. Flüh und J. Horstmann (2020): CATMA. Zenodo. DOI: 10.5281/ZENODO.4353618(link is external).

Münz-Manor, O., O. Mishali und Y. Erez (2023) Vis-À-Vis: Pattern Recogniton in Annotated Texts. <https://visavis.ouproj.org.il/index> (letzter Zugriff: 24.03.2025)

Schumacher, M. (2023b) forTEXT-Lerneinheit word2vec. <https://github.com/forTEXT/forTEXT.net/blob/main/word2vec/LerneinheitWord2Vec.ipynb> (letzter Zugriff: 01.03.2025).

Schumacher, M. (2022) Preprocessing mit NLTK. <https://github.com/forTEXT/forTEXT.net/blob/main/Preprocessing%20mit%20NLTK/Preprocessing%20mit%20NLTK.ipynb> (letzter Zugriff: 08.03.2024).

8.3 Abbildungsverzeichnis

Abb. 1: Arbeitsablauf der reflektierten literarischen Textanalyse, Pichler & Reiter (2022)

Abb. 2: Prüfung Word2Vec-Modell Beispiel 1

Abb. 3: Prüfung Word2Vec-Modell Beispiel 2

Abb. 4-8: Beispiel der Ähnlichkeitswerte von 5 Entitäten der Kategorie *Wald*

Abb. 9: t-SNE Visualisierung „Umweltphänomene_semantische Felder“ in Word2Vec.

Abb. 10: Kuchendiagramm des gesamten Korpus (*Arktis* und *Südamerika*) in Vis-À-Vis.

Abb. 11: Annotationsverteilung im Korpus *Arktis* in Vis-À-Vis.

Abb. 12: Annotationsverteilung im Korpus *Südamerika* in Vis-À-Vis

Abb. 13: Ausschnitt der Liste bezüglich der Kollokation *Insel*

Abb. 14: Netzwerk in Gephi der MFNE der jeweiligen Kategorien zu *Landschaft* und *Naturphänomene* und ihren mit Word2Vec analysierten ähnlichsten Wörtern.

Abb. 15: Netzwerkvisualisierung der Adjektiv-Kollokationen zu den häufigsten Entitäten des Gesamtkorpus.



Antiplagiatserklärung

Februar 2024

Die aktuelle Antiplagiatserklärung muss vollständig ausgefüllt und eigenhändig unterschrieben zusammen mit jeder schriftlichen Hausarbeit abgegeben werden.

Name, Vorname:	Friedrich, Antonia; Li, Mengjiao; Schulze, Judith
Matrikelnummer:	3489000; 3392731, 3318249
Hiermit versichere ich, die Arbeit mit dem Titel:	Annotation von Umweltphänomenen in der Reiseliteratur des 18. bis 20. Jahrhundert
im Rahmen der Lehrveranstaltung:	Annotation von Umweltphänomenen
Prüfungsnummer:	1081810000
im Sommer- / Wintersemester:	WiSe 24/25
bei (Dozent / Dozentin):	Prof. Dr. Mareike Schumacher

selbständig und nur mit den in der Arbeit angegebenen Hilfsmitteln verfasst zu haben. Die Seminararbeit ist in dieser oder ähnlicher Form in keinem anderen Kurs vorgelegt worden.

Plagiat als Form des geistigen Diebstahls besteht darin, wissenschaftliche Erkenntnisse, Hypothesen, Ideen oder Formulierungen anderer als eigene auszugeben. Die Verwendung von Quellen ist unbefugt, wenn notwendige Belege unterbleiben. Dies ist schon der Fall, wenn es sich nur um einen Satz, ein Satzfragment, einen Gedanken oder einen Absatz innerhalb der gesamten Arbeit handelt. Vgl. die Leitlinien der DFG zur „Sicherung guter wissenschaftlicher Praxis“ von 2022 (Stand April 2022) unter <https://www.dfg.de/resource/blob/173732/4166759430af8dc2256f0fa54e009f03/kodex-gwp-data.pdf> (22.02.2024). Besteht bei einer studentischen Leistung der begründete Vorwurf eines Plagiats, bei dem Textfragmente oder ganze Textpassagen und / oder Argumentationszusammenhänge anderer ohne Beleg (Primär- und Sekundärliteratur, gedruckt oder online) übernommen wurden, wird die Seminarleistung als „nicht ausreichend“ (5,0) bewertet. In schwerwiegenden Fällen kann der Prüfungsausschuss den Kandidaten / die Kandidatin von der Erbringung weiterer Prüfungsleistungen ausschließen.

Ich erkläre mit meiner Unterschrift, dass ich diese Arbeit selbständig verfasst habe und keine anderen als die angegebenen Quellen benutzt habe. Alle Stellen dieser Arbeit, die dem Wortlaut, dem Sinn oder der Argumentation nach anderen Werken entnommen sind (einschließlich des World Wide Web und anderer elektronischer Text- und Datensammlungen), habe ich unter Angabe der Quellen vollständig kenntlich gemacht. Jede Nutzung von KI-Tools, die im Zusammenhang mit meiner Arbeit stand, habe ich per Screenshot dokumentiert. Diese Dokumentationen sind Teil der digitalen Abgabefassung und dieser unbedingt beizufügen. Sie sind nicht Bestandteil der ausgedruckten Hausarbeit.

Ich bestätige hiermit, dass ich von der Antiplagiatserklärung am Historischen Institut der Universität Stuttgart Kenntnis genommen habe.

Stuttgart, 28.03.2025
Ort, Datum

A. Friedrich; Mengjiao Li; J. Schulze
Unterschrift



Fakultativer Fragenkatalog zur Eigenreflexion

Wissenschaftliche Arbeiten entstehen auf jeder Qualifikationsebene im Austausch mit anderen und mit allerlei Hilfsmitteln.

Um Sie dafür zu sensibilisieren, Sie ggfs. für die Nutzung mancher Hilfsmittel zu motivieren, haben wir die Antiplagiatserklärung um einen fakultativen Fragenkatalog zur Eigenreflexion ergänzt. Machen Sie kurz Angaben zu den folgenden Punkten und reflektieren Sie auf ca. einer Seite, wobei und inwiefern sich die Hilfsmittel als praktikabel erwiesen haben. Die Angaben und die Reflexion gehen nicht in die Benotung der Arbeit ein.

Ich habe folgende Hilfsmittel bei der Erstellung meiner Arbeit in Anspruch genommen:

- ☒ Sprechstundentermine mit dem oder der Dozierenden
- ☒ Gespräche mit anderen über das Thema meiner Arbeit (Freunde, Kommilitonen und Kommilitoninnen, Familienmitglieder ...)
- ☒ Sprachliche Nachschlagewerke (Online-Wörterbücher, Synonymdatenbanken ...)
- ☐ Nicht als Quelle angegebene Webseiten, etwa um mir einen ersten Überblick über bestimmte Themen zu verschaffen oder Anregungen zu holen (Wikipedia, Webseiten von Unis, Schulwebseiten ...)
- ☒ Chatbots und KI-Tools, etwa um mir Ideen zu holen, um eigene Formulierungen zu verbessern o. a. (ChatGPT, DeepL Write ...) zu übersetzen
- ☒ Ich habe meine Arbeit von anderen lektorieren lassen
- ☐ Andere, welche?

Für die Überprüfung der Rechtschreibung: DUDEN online und DeepL
